

TEF-RAG: Temporal Evidence Flow Retrieval-Augmented Generation

Juxian Yin

Abstract—xxx

I. 引言

随着大规模储能系统逐渐承担调峰、调频和新能源消纳等关键任务，储能电站的运行维护正在从传统的人工巡检逐步走向智能诊断与辅助决策。与开放域问答不同，运维任务并不是从一份静态文档中寻找一个局部答案：一次故障处置往往需要同时参考设备状态、告警与巡检记录、历史工单、操作规程以及后续验证结果，并根据这些证据之间的先后关系判断故障如何演化、哪些判断已经被后续记录修正，以及当前应当执行何种操作。因此，对于面向储能电站具身运维的智能系统而言，关键问题不仅是“检索哪些证据与查询语义相关”，还包括“在当前查询时刻哪些证据已经可知”以及“这些证据能否共同组成支持当前决策的完整过程”。系统的最终任务也不是生成一段自由文本答案，而是将可信证据进一步组织为一个字段完整、格式规范的标准化工单，以及一个满足规程、安全依赖和物理执行顺序的有序具身指令序列。

检索增强生成 (Retrieval-Augmented Generation, RAG) 通过在大语言模型生成前检索外部知识，有效缓解了模型参数知识过时以及领域知识不足的问题 [1]。现有 RAG 系统通常首先根据查询与文档之间的语义或词法相关性获得候选，再将排名靠前的若干文本片段作为生成上下文。这一范式适用于大量静态知识问答任务，但直接应用于持续更新的运维记录时存在两个明显局限。

首先，运维知识具有显著的双时间属性。一条记录既有其描述事件实际发生的时间，也有其进入信息系统并能够被检索到的时间。晚到的巡检报告、补录工单以及事后形成的诊断结论，可能描述较早发生的事件，却不应被更早时刻的查询提前使用。同时，同一设备状态和故障认识还可能随着后续检查不断更新甚至被推翻。因此，仅按照语义相关性或简单的新鲜度排序，难以保证检索结果符合查询时刻真实可获得的知识状态。

其次，一次运维决策通常依赖多个相互关联的证据。例如，异常状态可以触发检查，检查结果支持某一诊断，诊断进一步引出维修动作，而维修后的复测记录又用于验证处置结果。这些证据单独来看都可能不是查询中最相似的文本，但组合起来却构成完成任务所必需的证据链。传统 Top- k 检索通常独立评价每篇文档，容易得到若干局部相关但功能重复的记录，同时遗漏连接观察、诊断、处置和验证过程的关键证据。更一般地说，目标并不一定是一条严格线性的链，而可能是包含分支、更新、限定与不确定性保留的有向证据结构。

近年来，研究者开始显式研究 RAG 中的时间因素。MRAG 将查询拆分为语义内容与时间约束，分别计算证据的语义相关性和时间相关性，以改善时间敏感问题的检索效果 [2]；TA-RAG 则进一步面向跨时间区间的 diachronic

question answering，联合主题语义与时间窗口寻找时间上连贯的证据集合 [3]。这些研究表明，将时间条件显式引入检索过程比仅依赖通用语义相似度更适合动态知识环境。另一方面，多跳检索和结构化 RAG 也说明，复杂问题往往需要联合多个互补证据，而不是独立选择若干相似片段。Multi-Hop Dense Retrieval 通过逐跳条件化检索为复杂问题收集多段证据 [5]；RAPTOR 通过递归聚类与摘要构建层次化检索结构 [4]；GraphRAG 则利用实体图与社区摘要组织大规模文本语料 [6]。然而，这些结构主要来自文档层级、实体联系或多跳问答过程，并不直接表示持续更新的运维记录之间支持、更新、限定、冲突、替代和验证等查询相关关系。当一个查询需要恢复从状态变化到处置结果的完整过程时，时间相关的单条证据排序或预先构建的静态结构仍不能直接保证所选证据集合在流程上完整。

针对上述问题，本文提出 **TEF-RAG (Temporal Evidence Flow Retrieval-Augmented Generation)**，面向储能电站运维记录构建查询条件化的时序证据流。TEF-RAG 不再将候选记录视为彼此独立的文档，而是首先在查询时刻可见的候选证据之间建立有向语义关系，并将支持、更新、限定、验证、替代和不确定性传播等关系组织为 *Temporal Evidence Flow*。在此基础上，系统从候选证据中联合选择一组能够覆盖任务所需角色、保持时间方向并形成有效关系结构的记录，而非单纯截取相关性最高的若干文档。

具体而言，TEF-RAG 首先通过基础检索得到候选证据，并保留资产范围、事件时间与可用时间、规程适用性等确定性条件作为候选合法性的基本边界。这些规则主要用于排除在当前查询下不可使用的证据。随后，系统利用查询条件化的关系判断识别候选证据之间的语义联系，并通过学习式 pair proposal 减少需要进行关系判断的证据对数量。最后，与传统逐条文档打分不同，TEF-RAG 对完整候选证据集合进行联合评价：采用基于 pairwise ranking 的非线性集合效用模型，结合困难负样本挖掘，学习区分能够形成完整证据流的集合与语义上相关但结构不完整的集合，最终选择固定规模的证据流，并将其作为下游生成器的受控上下文，生成标准化工单和有序具身指令序列。需要说明的是，本文的核心算法贡献仍集中于这一端到端任务中的检索与证据组织层：检索实验检验系统能否在正确的时间边界内恢复完整、连贯的证据流；在此基础上，本文进一步固定同一下游生成器，对五种检索上下文进行结构化工单与动作计划评价，用于检验上游 evidence-flow 质量是否能够传递为更好的生成质量。该下游评价不等同于真实机器人执行有效性或闭环安全验证。

本文的主要贡献如下：

- 1) 提出面向动态运维知识的时序证据流检索问题。区别于独立文档相关性排序，本文从查询时刻可见性和证据间有向关系两个层面描述动态运维知识，将检索目

标从单条证据相关性扩展为证据集合的流程完整性。

- 2) **提出查询条件化的证据关系建模与候选关系生成机制。**在基础候选检索之后, TEF-RAG 对证据之间的支持、更新、限定、验证、替代等关系进行语义判断, 并利用学习式 pair proposal 在受控计算预算下优先选择与当前查询相关的候选证据对, 从而构建稀疏的时序证据流。
- 3) **提出面向完整证据集合的非线性排序方法。**本文不独立预测每条证据的重要性, 而是在固定候选集合空间中直接学习不同证据组合之间的相对效用, 并通过 query-level pairwise ranking 与困难负样本挖掘建模证据角色、时间结构和关系结构之间的非线性交互, 使最终选择目标与完整证据流检索更加一致。
- 4) **构建并封存面向时序运维证据检索的受控评价协议。**评价同时考察传统的 Recall 和 nDCG, 以及证据组完整性、时序关系完整性等集合级指标, 并严格区分开发、验证与封存测试阶段。该设置用于分析普通相关性检索、时间感知检索与证据流建模在动态运维场景中的能力差异。

A. 相关工作与研究差异

检索增强生成与结构化上下文组织。经典 RAG 将外部非参数知识库与生成模型结合, 通过检索相关文档为生成阶段提供可追溯的外部知识 [1]。随后研究逐渐从独立短文本检索扩展到更加结构化的上下文组织。RAPTOR 递归地对文本块进行聚类与摘要, 构建多层次树状索引, 使查询能够在不同语义粒度上获取信息 [4]; GraphRAG 则从语料中构建实体知识图和社区摘要, 利用图结构支撑跨文档的信息聚合 [6]。这类方法表明, 检索单元之间的组织结构会直接影响最终上下文质量。但其结构主要由文档层级或语料实体关系预先构建, 而 TEF-RAG 的关系图在查询时刻由当前可见运维证据动态形成, 并显式表示状态更新、规程约束、诊断支持及结果验证等有方向的关系。

时间感知 RAG 与动态知识检索。动态知识环境下, 仅依据语义相似度容易召回时间上不适用的事实。MRAG 将问题中的主题内容和时间约束分离, 通过语义-时间联合排序处理 time-sensitive question answering [2]。TA-RAG 面向需要跨时间观察实体变化的 diachronic questions, 进一步强调证据在目标时间区间上的连续覆盖 [3]。本文与这些工作的共同点是显式建模时间条件, 但问题设定更强调知识可见性而不仅是时间相关性: 一条较早发生的记录如果在查询截止时刻之后才进入系统, 仍不能被当前查询使用。此外, TEF-RAG 不仅判断单条证据是否处于目标时间范围, 还要求所选多条证据能够通过有向关系形成完整的任务相关证据流。

多跳证据检索与集合级选择。复杂问答通常需要联合多个互补证据。Multi-Hop Dense Retrieval 通过前一跳结果条件化后续检索, 在无需预定义语料图结构的情况下收集多跳证据 [5]。这类方法的核心是逐步扩展检索路径; TEF-RAG 则不把目标限定为单一线性路径, 而是先在候选证据之间建立查询条件化的 typed directed graph, 再对固定大小的证据集合进行联合排序。因此, 本文的重点不是“下一跳文档是哪一条”, 而是“一个候选集合能否同时覆盖必要角色, 并在时间方向和关系结构上组成可用于当前决策的完整证据流”。这一区别也决定了本文采用集合级

Complete/FlowComplete 指标, 而不是仅以单条文档相关性或逐跳命中率衡量检索质量。

面向机器人/具身运维的 RAG 与电池时序辅助决策。检索结果在本文中最终服务于具身运维任务规划, 而非停留在问答层。SayComply 将操作要求、环境条件与机器人能力组织为层级知识, 利用检索结果约束现场机器人任务满足操作合规要求 [7]; RAGLRO 进一步在电力开关柜操作场景中利用操作手册与安全协议生成机器人控制指令, 验证了 RAG 与专业设备操作规划结合的可行性 [8]。在电池与储能相关任务中, LiBrain 强调由专业时序模型承担预测、RAG 提供领域知识、LLM 进行综合推理的分工 [9]; TimeSeries2Report 则探索将多变量电池时序数据转换为结构化语义报告, 再供语言模型进行状态管理与决策 [10]。这些工作与本文的应用目标一致, 即将外部知识与动态状态最终转化为可执行任务。本文的研究差异在于: 不直接把生成器作为主要创新对象, 而是集中解决生成之前的证据选择问题, 使标准化工单与有序具身指令建立在查询时刻可见、关系一致且流程完整的证据上下文之上。

II. 问题定义与符号约定

A. 查询、证据与查询时刻知识快照

给定运维请求 q , 其部署时可见信息表示为

$$Q_q = (x_q, u_q, m_q, t_q), \quad (1)$$

其中 x_q 为请求文本, u_q 为目标资产, m_q 为资产型号或上下文, t_q 为本次回答允许使用知识的截止时刻。与初版系统相同, 本文显式区分事件发生时间和信息进入系统的时间; 不同之处在于, 后续检索目标不再是按来源拼装若干独立记录, 而是从当前时刻可见的异构证据中恢复一个查询相关的 Temporal Evidence Flow。

设全局证据库为

$$\mathcal{K} = \{e_1, e_2, \dots, e_N\}. \quad (2)$$

从具身运维应用的输入形态看, 可进一步写为

$$\mathcal{K} = \mathcal{D}_{\text{unstruct}} \cup \mathcal{D}_{\text{struct}} \cup \mathcal{D}_{\text{temporal}}, \quad (3)$$

其中 $\mathcal{D}_{\text{unstruct}}$ 包含运维手册、设备说明书和安全规程等非结构化文档, $\mathcal{D}_{\text{struct}}$ 包含历史故障、工单和设备台账等结构化记录, $\mathcal{D}_{\text{temporal}}$ 则表示 BMS/SCADA 状态及由专业预测模型产生的时序健康信息。TEF-RAG 在算法实现中将三类输入统一投影为可追踪来源的 evidence records, 但不假设它们原始形态相同。每条证据 e 至少包含文本或结构化内容 $z(e)$ 、资产标识 $u(e)$ 、来源类型 $s(e)$ 、事件类型 $c(e)$ 、事件时间 $t_e(e)$ 和可用时间 $t_a(e)$; 若证据属于规程、版本化诊断或工单, 还可包含型号范围、版本、有效区间、撤回时间及 supersession 等部署时可见元数据。

沿用初版论文的双时间可见性定义, 查询 q 能否使用证据 e 表示为

$$\text{Visible}(e, q) = \begin{cases} 1, & t_e(e) \leq t_q \wedge t_a(e) \leq t_q, \\ 0, & \text{otherwise.} \end{cases} \quad (4)$$

这里 $t_e(e)$ 表示事件实际发生时刻, $t_a(e)$ 表示该记录首次进入系统并可被检索的时刻。例如, 一条描述 10:00 告警、但在 10:10 才补录的记录, 不能用于截止时刻为 10:05 的

查询。因此, $t_e(e)$ 防止使用尚未发生的事件, $t_a(e)$ 则防止晚到信息被历史查询提前获知。

对于具有型号和版本约束的规程证据 d , 进一步沿用适用性条件

$$\text{Applicable}(d, q) = \mathbb{I}[m_q \in M_d] \mathbb{I}[t_d^- \leq t_q < t_d^+] \mathbb{I}[w_d = \emptyset \vee t_q \leq w_d] \quad (5)$$

其中 M_d 为规程支持的型号集合, t_d^- 与 t_d^+ 分别表示生效与失效时刻, w_d 为撤回时刻; 无明确失效时刻时令 $t_d^+ = +\infty$ 。型号、有效期和撤回状态都属于确定性合法性边界, 不由后续学习模型重新推断。

综合资产范围、式 (4) 的双时间可见性以及必要的规程适用性条件, 得到查询时刻合法证据集合

$$C_q = \{e \in \mathcal{K} : \text{Legal}(e, Q_q) = 1\}. \quad (6)$$

所有候选检索、关系判断和集合排序都只能在 C_q 内进行。这一边界的作用是防止未来证据、错设备证据和无效规程进入后续学习过程, 而不是替代语义检索本身。

B. 端到端任务输出与评价边界

储能电站具身运维的最终目标是一个从多源输入到结构化、有序输出的映射。本文将最终输出表示为

$$Y_q = (W_q, A_q), \quad (7)$$

其中 W_q 为标准化工单, 其字段由固定 schema 约束, 可包含目标设备、查询/处置时刻、当前状态、诊断或处置结论、适用规程、证据引用以及未知/待确认项等; $A_q = [a_1, a_2, \dots, a_n]$ 为有序具身指令序列。每个 a_i 对应一个可执行的原子动作, 例如导航、测温、拍照、检查、操作或数据回传, 并可携带目标对象、参数、前置依赖和证据引用。

令 Δ_q 为动作依赖集合。若 $(a_i, a_j) \in \Delta_q$, 则动作 a_i 必须在 a_j 之前完成, 从而显式表示规程顺序、安全逻辑和物理依赖, 而不是把动作集合当作可任意交换的自然语言列表。在总体系统中, TEF-RAG 检索得到的证据流作为生成器的受控上下文:

$$(\hat{W}_q, \hat{A}_q) = g_w(x_q, \hat{S}_q, \mathcal{G}_q). \quad (8)$$

本文的核心算法贡献集中于式 (8) 之前的 evidence-flow retrieval: 即保证进入生成器的证据满足时间可见性、字段/规程适用性与集合流程完整性。Recall、nDCG、Complete 和 FlowComplete 用于评价这一上游证据质量。为进一步检验检索收益能否传递到任务输出, 本文在固定生成器条件下另行评价 W_q 的字段匹配、动作内容、证据引用与动作计划严格匹配。该生成评价仍不等同于真实机器人闭环执行或安全验证, 从而在保留端到端具身运维目标的同时, 明确区分 retrieval、structured generation 与 physical execution 三个层次。

C. Temporal Evidence Flow

基础检索器根据 x_q 从 C_q 中取得查询相关的候选节点集合 V_q 。TEF-RAG 随后不再把这些节点视为彼此独立的文档, 而是构建查询条件化的有向证据图

$$\mathcal{G}_q = (V_q, E_q), \quad (9)$$

其中一条边写作

$$(e_i, r_{ij}, c_{ij}, e_j) \in E_q, \quad (10)$$

$r_{ij} \in \mathcal{R}$ 是证据关系类型, $c_{ij} \in [0, 1]$ 为关系置信度。冻结的关系词汇表包含 *supports, governs, qualifies, contrasts, prerequisite, preserves uncertainty, resolves, supersession, updates, verifies*。边方向统一从时间上或前置关系上较早的支持状态指向下游结论、动作、更新或替代状态。因此, Temporal Evidence Flow 是一个允许分支和汇合的有向结构, 并不要求所有查询都能够压缩成唯一的线性证据链。

给定候选图 $\mathcal{G}_q$, 系统最终输出固定规模的证据集合

$$\hat{S}_q = \arg \max_{S \in \mathcal{B}_q, |S|=k} F_\theta(\phi(Q_q, S, \mathcal{G}_q)), \quad (11)$$

其中 $\mathcal{B}_q$ 为从候选节点构造的有限证据集合空间, $\phi(\cdot)$ 为集合级特征表示, F_θ 为学习到的非线性集合效用函数。本文正式设置取 $k = 5$ 。式 (11) 强调本文优化的是集合效用而不是五条独立文档分数之和; 集合中各证据的角色互补性、时间跨度、关系连通性和冗余程度都可能共同影响最终排序。

D. 集合级监督与离线评价边界

为评价一个 Top- k 集合是否覆盖任务所需证据, 对每个查询定义必要证据组

$$\Gamma_q^* = \{G_{q,1}^*, \dots, G_{q,M_q}^*\}, \quad (12)$$

其中每个 $G_{q,j}^*$ 表示一个必要功能角色的可接受证据 ID 集合。同一组内的多个 ID 只表示真正等价的 OR 替代; 需要同时出现的互补证据必须放在不同组中。因此, 一个选择集合 S 的组完整性条件为

$$\forall G \in \Gamma_q^*, S \cap G \neq \emptyset. \quad (13)$$

此外, 令 Φ_q^* 为必要 flow edge 集合。每条必要边连接两个必要组, 并给出允许的端点证据对和关系类型。若存在一个对所有必要组都全局一致的赋值 $a(G) \in S \cap G$, 使得每一条必要 flow edge 的端点对均属于其允许集合, 则称该检索结果满足 FlowComplete。这一存在性定义允许等价证据替换, 同时避免分别为不同边选择互相矛盾的证据端点。

需要强调的是, Γ_q^* 、 Φ_q^* 、答案摘要以及测试集 item-level review 均属于离线监督或评价信息, 推理阶段不可见。TEF-RAG 的 pair proposal、关系判断和集合排序只使用 Q_q 与部署时可见证据字段。这种边界与初版论文中“参考标注只进入离线评价”的原则一致, 但新版协议进一步把监督对象从独立必要证据扩展为必要证据组和 typed evidence flow。

III. TEF-RAG 方法

- 候选证据准备与时序合法性
- 学习式 Pair Proposal 与查询条件化关系判断
- 候选证据集合构造
- 非线性 Pairwise Set Ranking 与困难负样本挖掘
- 证据流驱动的标准化工单与具身指令生成接口

IV. 实验设计

A. TEF-RAG v6 Semantic Benchmark v1

总体定位与规模。本文使用新构建并封存的 **TEF-RAG v6 Semantic Benchmark v1**。该数据集是一个 *public-source-grounded, AI-assisted synthetic benchmark*: 公开制

Figure placeholder: TEF-RAG overall architecture.

Query + temporally valid candidate pool $\rightarrow$ learned pair proposal $\rightarrow$ query-conditioned relation reasoning $\rightarrow$
Temporal Evidence Flow graph $\rightarrow$ candidate set construction $\rightarrow$ nonlinear pairwise set ranking $\rightarrow$ Top-5
evidence flow $\rightarrow$ grounded generation $\rightarrow$ standardized work order + ordered embodied instruction sequence.

Fig. 1. TEF-RAG 总体框架。系统先从查询时刻合法的候选证据中构建查询条件化的时序证据图，再对候选证据集合进行非线性 pairwise ranking，以恢复完整的 Top-5 evidence flow；该证据流随后作为受控上下文生成标准化工单与有序具身指令序列。本文 v6 封存 benchmark 重点评价图中 evidence-flow retrieval 部分。

TABLE I
主要符号及定义

符号	含义
Q_q, x_q, u_q, m_q, t_q	查询、文本、目标资产、型号/上下文与知识截止时刻
$t_e(e), t_a(e)$	证据事件发生时刻与首次可用时刻
$\mathcal{K}$	全局异构证据库
$\mathcal{C}_q$	查询 q 的合法可见证据集合
$\text{Applicable}(d, q)$	规程 d 对查询 q 是否适用
$\mathcal{G}_q = (V_q, E_q)$	查询条件化 Temporal Evidence Flow 图
$\mathcal{R}$	typed evidence relation 集合
$\mathcal{B}_q$	查询 q 的候选证据集合空间
$\hat{\mathcal{S}}_q$	最终选择的 Top- k 证据集合，本文 $k = 5$
$Y_q = (W_q, A_q)$	最终运维输出：标准化工单与有序具身指令序列
Δ_q	具身指令之间必须满足的动作依赖集合
Γ_q^*	离线必要证据组集合
Φ_q^*	离线必要 flow edge 集合

造商资料和公开研究数据只用于约束产品类别、数值范围和采样先例，而运维因果故事、诊断演化、规程情境和查询任务由受控语义生成流程构造。因此，本文不将其描述为真实电站运行数据、专家标注数据或现场认证 SOP。该 benchmark 首先评价端到端具身运维系统中的检索与证据组织层：系统需要从异构动态记录中恢复足以支撑后续工单与动作规划的 Temporal Evidence Flow。在此基础上，本文进一步构建独立的结构化生成 gold，评价检索质量能否传递为下游工单和动作计划质量。

数据集包含 100 个目标资产、400 条完整事件链、3888 条证据记录、1200 个 primary intents 和 2400 条 query rows。每条 chain 包含 3 个语义不同的 primary intents，每个 intent 生成 2 个确定性 paraphrases，因此每条 chain 对应 6 条查询。两种难度层各包含 200 条 chain: *Realistic Distribution Set* 用于覆盖较常见的时序运维组合，*Temporal-Hard Challenge Set* 则有意增加晚到证据、版本替换、多 episode 对比、跨来源互补证据以及持续不确定性等情形。两个层均按 chain 进行 60/20/20 的

development/validation/test 划分，保证同一 chain 的不同 intent 和 paraphrase 不跨数据划分。统计见表 II。

公开资料约束。新版 benchmark 建立明确的 source registry。其中，HiTHIUM 280Ah LFP 数据表用于约束 280Ah-class 方形磷酸铁锂电芯的标称电压、工作电压/温度范围以及制造商给出的倍率信息 [11], [12]; REPT BATTERO 的储能资料用于提供跨制造商的 280Ah/3.2V stationary-LFP 背景参照 [13]; RWTH Aachen University 发布的 M5BAT 数据记录则用于提供储能现场数据采用秒级采样的公开先例 [14]。这些公开资料只约束物理/产品背景，并不为本文合成的故障发生率、站级保护阈值、维护因果故事或具体工单动作背书。

语义生成与证据流标注。数据生成以 chain 为基本单元，而不是独立随机生成 query-document 对。每条 chain 先确定目标资产、时间轴和一组相互关联的 evidence records，再围绕同一事件过程构造观察、检查、诊断、规程适用性、工单、更新、纠正、验证或不确定性分支等节点。困难层额外加入 late-arriving evidence、被后续版本替代的 procedure/diagnosis、跨 episode 的相似模式和必须共同出现的跨来源证据。在每条 chain 上进一步编写 3 个不同 primary intents，并为每个 intent 产生 2 个语义保持的确定性 paraphrases。离线 gold 为每个 intent 定义 required groups 与 required flow edges，从而区分“召回若干相关证据”和“召回能够组成全局一致任务 flow 的证据”。

语义复核与封存。benchmark 在方法正式测试前完成冻结。Validation 的 formal second blind semantic review 覆盖全部 80 条 validation chains，80/80 通过且无 unresolved case; Test 的 second blind review 同样覆盖全部 80 条 test chains / 480 条 query rows，80/80 通过且两遍语义复核无 disagreement。正式 test evaluator 在模型开发和预测冻结阶段保持隐藏；所有正式实验完成后，为复现目的公开完全相同的历史 evaluator 字节，其 SHA-256 为 477bb709f3dfdb672ce5a7f5c93168e0791c7a90cb247c62a6072bd8d

B. 结构化生成评价集

为检验 evidence-flow retrieval 的收益是否能传递到最终结构化输出，本文在同一 400 条 authored chains 上构建独立的 generation gold。每个 primary intent 对应一

TABLE II
TEF-RAG v6 SEMANTIC BENCHMARK v1 规模与划分

统计项	Development	Validation	Test	Total
Realistic Distribution chains	120	40	40	200
Temporal-Hard Challenge chains	120	40	40	200
全部 authored chains	240	80	80	400
Primary intents	720	240	240	1200
Query rows	1440	480	480	2400
Target assets	—	—	—	100
Evidence records	—	—	—	3888
Paraphrases / intent	2 (同一 intent 的鲁棒性改写, 不视为独立事件)			

TABLE III
结构化生成 GOLD 的规模

Split	Chains	Semantic gold	Query rows
Development	240	720	1440
Validation	80	240	480
Test	80	240	480
Total	400	1200	2400

个 semantic gold object, 并由同一 intent 的两个 paraphrases 共享; 因此 development/validation/test 分别包含 720/240/240 个 semantic gold objects, 覆盖 1440/480/480 条 query rows, 见表 III。

每个 gold 输出由两部分组成: 标准化工单 `work_order` 与动作计划 `action_plan`。工单包含资产、诊断、推荐动作、适用规程、验证/不确定性状态及证据引用; 动作计划由若干原子动作组成, 每个动作具有类型、目标、参数、`depends_on` 依赖和 supporting evidence IDs, 因而能够表示一个有向无环的动作依赖结构。全部 1200 个 semantic gold objects 均通过 schema、时间可见性、规程适用性、citation/provenance、动作 DAG 与 paraphrase consistency 检查, 未留下 unresolved annotation。

Generation gold 在读取 retrieval test metrics、sealed retrieval evaluator 或任何 generation evaluation 输出之前完成, 并在正式 test generation 前保持隐藏。正式 blind generation evaluation 完成后, test gold 与 index 才公开用于复现; 其中 test gold 包含 240 个 semantic objects, index 将其确定性映射到 480 条 test queries。

C. 对比方法

正式比较包含五种检索上下文: BM25、BGE Reranker、Temporal-BM25、TA-RAG 与 TEF-RAG。BM25 提供纯词法基线; BGE Reranker 在 BM25 Top-30 上使用 BAAI/bge-reranker-v2-m3 进行通用语义重排; Temporal-BM25 在词法相关性上加入冻结的 query-conditioned temporal score; TA-RAG 采用其官方 temporal parsing、NCLS temporal filtering、Nomic embedding 与 reranking 机制; TEF-RAG 则使用本文提出的查询条件化 relation graph 与 nonlinear pairwise set ranking。所有方法最终均输出 Top-5 original evidence IDs。

D. 实验设置与冻结协议

Retrieval test 在所有方法配置冻结后进行一次正式评估。正式 test prediction 在 evaluator 访问前写入 prediction manifest 并固定 SHA-256, 之后只由 sealed evaluator 读取并计算 aggregate metrics。

Generation comparison 固定使用同一个下游生成器, 以隔离“不同检索上下文”对生成质量的影响。五种方法均使用同一 DeepSeek `deepseek-flash` 模型、同一 prompt/schema、temperature = 0、thinking disabled, 并最多允许一次 schema/grounding repair; 除输入的 Top-5 evidence 外, 其余生成设置保持一致。Test 上每种检索方法产生 480 条 generation predictions, 共 2400 条正式预测。若一次 repair 后仍不满足 schema/grounding 约束, 该输出仍保留并由 evaluator 直接计入相应惩罚, 而不进行人工替换或删除。

E. 评价指标

Retrieval. 主指标为 Recall@5、nDCG@5、Complete@5 与 FlowComplete@5。Complete@5 要求 Top-5 至少覆盖每个 required group; FlowComplete@5 进一步要求存在一个全局一致的 group-to-evidence assignment, 同时满足全部 required flow edges。Hit@5、Edge Recall 与 uncertainty accuracy 作为辅助诊断。

Generation. 完整 evaluator 记录 schema、字段、动作、依赖、顺序、citation、evidence support 与严格端到端指标。为避免主表指标过载, 正文只报告四项与论文研究问题最直接相关的指标: (1) **Field Macro F1 (strict)**, 对工单关键标量字段进行 canonicalization 后的宏平均严格匹配; (2) **Action F1**, 在 action type、target 与 parameters 规范化后进行最大一一匹配所得的动作级 F1; (3) **Citation F1**, 衡量诊断/规程/验证声明及动作与 supporting evidence 之间的 claim-evidence links; (4) **Plan EM (strict)**, 要求动作集合、recommended-action 映射以及动作依赖的传递闭包与 gold 完全一致。其余 schema validity、dependency/order 与 end-to-end strict 指标用于诊断, 并在讨论中用于界定结论强度。

V. 实验结果

A. 检索主结果

表 IV 给出 frozen test split 上的正式结果。TEF-RAG 在 Recall@5、nDCG@5、Complete@5 与 FlowComplete@5 四项主指标上均取得最高值。相较于这些指标上最强的

TABLE IV
FROZEN RETRIEVAL TEST 的主结果 (Top-5)

Method	Recall	nDCG	Complete	FlowComplete
BM25	0.3791	0.3915	0.0563	0.0563
BGE Reranker	0.2916	0.3070	0.0417	0.0417
Temporal-BM25	0.4591	0.4955	0.0792	0.0792
TA-RAG	0.2769	0.2907	0.0375	0.0375
TEF-RAG	0.7228	0.6231	0.3188	0.3146

TABLE V
FROZEN GENERATION TEST 的主要结构化生成指标

Method	Field F1	Action F1	Citation F1	Plan EM
BM25	0.4715	0.1372	0.0813	0.0167
BGE Reranker	0.4129	0.1198	0.0405	0.0146
Temporal-BM25	0.5218	0.1637	0.1249	0.0167
TA-RAG	0.4059	0.1115	0.0379	0.0188
TEF-RAG	0.5345	0.2035	0.1585	0.0417

非 TEF baseline (均为 Temporal-BM25), TEF-RAG 的 Recall@5 从 0.4591 提升至 0.7228, nDCG@5 从 0.4955 提升至 0.6231; 更明显的差异出现在集合级完整性: Complete@5 从 0.0792 提升至 0.3188, FlowComplete@5 从 0.0792 提升至 0.3146。这说明仅加入时间偏好能够改善单条证据召回, 但显式建模 evidence-flow 关系并联合选择证据集合, 对恢复完整任务支持结构更为关键。

B. 下游结构化生成结果

表 V 只保留最能回答“更好的 evidence flow 是否改善最终工单与动作计划”的四项生成指标。在相同 generator、prompt、schema 与 decoding 设置下, TEF-RAG 在四项指标上均取得最高值: Field Macro F1 为 0.5345, Action F1 为 0.2035, Citation F1 为 0.1585, Plan EM (strict) 为 0.0417。相较各指标上最强的非 TEF baseline, Action F1、Citation F1 与 Plan EM 分别取得约 24.3%、26.9% 与 122.2% 的相对提升; Field Macro F1 相较 Temporal-BM25 提升约 2.4%。结果表明, TEF-RAG 的收益不仅体现在上游检索命中率, 也能够传递到工单关键字段、处置动作和证据引用质量。

需要强调的是, 这些结果支持的是“生成内容更加准确和更有证据支撑”, 而不是“完整工单已经被可靠解决”。五种方法的 `work_order_em_strict`、`end_to_end_em_strict` 与 `task_success` 均为 0; 与此同时, schema validity 仍处于 0.9875–0.9958 的高水平。这说明失败并非主要来自 JSON/schema 崩溃, 而是完整工单需要多个字段、动作集合、依赖关系和引用同时严格匹配, 当前系统仍难以满足这一组合条件。因此, 本文将生成结果表述为: **TEF-RAG 提高了生成工单的字段级准确性、动作正确性和计划级一致性**, 而不声称已经生成完全正确的工单与具身指令序列。

C. 进一步分析

TEF-RAG 并非在所有生成诊断指标上都占优。例如, TA-RAG 的 Dependency F1 为 0.3271、Order Validity 为 0.4125, 均高于 TEF-RAG 的 0.2858 与 0.3146。这一现象表明, evidence-flow retrieval 更直接改善的是“提供哪些事实和动作依据”, 而动作之间的全局依赖与执行顺序

仍受到下游 planner/generator 本身能力的限制。换言之, 上游证据组织已经显著改善 factual grounding 与 action fidelity, 但尚不足以单独解决完整的全局计划组合问题。

VI. 讨论

检索与生成两层结果形成了相互补充的证据链。Retrieval test 中, TEF-RAG 对 Complete@5 与 FlowComplete@5 的提升显著大于单条相关性指标的提升, 说明方法确实更擅长恢复互补且关系一致的证据集合; 在完全固定的下游生成器上, 这种上下文优势又对应更高的 field、action、citation 与 strict plan matching。因此, 实验更支持“Temporal Evidence Flow 改善 retrieval-to-generation 的信息传递”这一结论, 而不是把收益归因于更强的生成模型。

另一方面, Plan EM 仍只有 0.0417, 且所有方法的严格 end-to-end exact match 为 0, 说明结构化运维生成仍是一个远未解决的问题。未来工作应将证据流与显式 planner、约束解码、动作图验证以及真实机器人安全执行检查结合, 而不能仅依赖语言模型从 Top-5 上下文直接完成全部规划。

VII. 局限性与有效性威胁

本文 benchmark 是 public-source-grounded、AI-assisted synthetic benchmark, 而非真实电站工单或领域专家标注数据; 因此其主要价值是受控比较 temporal evidence retrieval 机制, 不能直接外推到真实电站故障频率或机器人现场安全性。此外, test gold 在正式实验后已公开以支持复现, 因此未来新方法若需要保持 blind evaluation, 应构建新的 sealed test split, 而不应继续把当前 test 当作未见数据。生成评价虽然覆盖字段、动作、依赖与引用, 但没有模拟实际机器人执行、环境反馈和安全联锁; 严格端到端指标为 0 也表明 planner/generator 仍是明显瓶颈。

VIII. 结论

本文提出 TEF-RAG, 将动态运维 RAG 的检索目标从独立文档相关性扩展为查询时刻可见、关系一致且流程完整的 Temporal Evidence Flow。在冻结的 temporal-hard benchmark 上, TEF-RAG 在 Recall@5、nDCG@5、Complete@5 与 FlowComplete@5 上均超过四种对比方法; 在固定下游生成器的结构化 generation test 中, TEF-RAG 同时取得最高的字段级匹配、Action F1、Citation F1 与 strict Plan EM。这些结果说明, 面向证据集合及其时序关系的检索能够改善进入生成器的任务支持上下文, 并进一步提高工单字段、维护动作与证据引用的准确性。完整工单和具身动作序列的严格端到端生成仍未解决, 后续工作需要进一步结合显式计划与执行约束。

REFERENCES

- [1] P. Lewis, E. Perez, A. Piktus, *et al.*, “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474, 2020.
- [2] S. Zhang, Y. Xue, Y. Zhang, X. Wu, A. T. Luu, and C. Zhao, “MRAG: A Modular Retrieval Framework for Time-Sensitive Question Answering,” in *Findings of the Association for Computational Linguistics: EMNLP 2025*, pp. 3080–3118, 2025, doi: 10.18653/v1/2025.findings-emnlp.167.
- [3] K. H. Lau, R. Zhang, W. Shi, X. Zhou, and X. Cheng, “Reading Between the Timelines: RAG for Answering Diachronic Questions,” *arXiv preprint arXiv:2507.22917*, 2025.

- [4] P. Sarthi, S. Abdullah, A. Tuli, S. Khanna, A. Goldie, and C. D. Manning, "RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval," in *The Twelfth International Conference on Learning Representations (ICLR)*, 2024.
- [5] W. Xiong, X. L. Li, S. Iyer, J. Du, P. Lewis, W. Y. Wang, Y. Mehdad, W.-t. Yih, S. Riedel, D. Kiela, and B. Öguz, "Answering Complex Open-Domain Questions with Multi-Hop Dense Retrieval," in *International Conference on Learning Representations (ICLR)*, 2021.
- [6] D. Edge, H. Trinh, N. Cheng, J. Bradley, A. Chao, A. Mody, S. Truitt, D. Metropolitan, R. O. Ness, and J. Larson, "From Local to Global: A Graph RAG Approach to Query-Focused Summarization," *arXiv preprint arXiv:2404.16130*, 2024.
- [7] M. F. Ginting, D.-K. Kim, S.-K. Kim, B. J. Krishna, M. J. Kochenderfer, S. Omidshafiei, and A.-A. Aghamohammadi, "SayComply: Grounding Field Robotic Tasks in Operational Compliance through Retrieval-Based Language Models," in *Proc. IEEE International Conference on Robotics and Automation (ICRA)*, pp. 13730–13736, 2025.
- [8] W. Wang, *et al.*, "RAGLRO: Retrieval-Augmented Generation With Large Language Models for Robotic Operations," *CAA Transactions on Intelligence Technology*, vol. 11, no. 2, pp. 385–395, 2026, doi: 10.1049/cit2.70105.
- [9] Z. Li, *et al.*, "LiBrain: LLM-Powered Li-ion Battery Diagnostics with Time-Series-Aware Retrieval-Augmented Framework for E-bikes," in *Proc. AAAI Conference on Artificial Intelligence*, vol. 40, no. 47, pp. 40045–40053, 2026, doi: 10.1609/aaai.v40i47.41439.
- [10] J. Yang, M. Guay, Z. Cao, and C. Zhao, "Time-Series2Report Prompting Enables Adaptive Large Language Model Management of Lithium-Ion Batteries," *arXiv preprint arXiv:2512.16453v2*, 2026.
- [11] HiTHIUM, "HiTHIUM V1.1 ESS Cell 280 Ah EU English Datasheet," V1.1, Jun. 12, 2023. [Online]. Available: https://hithium.com/fileadmin/ns_theme_hithium/pdf/HiTHIUM_Data-Sheet_ESS-Cell280Ah_V1-1_EU_EN_230612.pdf
- [12] HiTHIUM, "280 Ah LFP Cell Datasheet," V3.3, Sep. 18, 2024. [Online]. Available: <https://cn.hithium.com/bocupload/2024/11/14/17315688038239mc70h.pdf>
- [13] REPT BATTERO, "Energy Storage Promotional Brochure," 2025. [Online]. Available: <https://www.reptbattero.com/wp-content/uploads/2025/10/REPT-BATTERO-ENERGY-STORAGE-PROMOTIONAL-2510.pdf>
- [14] RWTH Aachen University, "M5BAT Battery Unit Pb1 2017–2025," 2026, doi: 10.18154/RWTH-2026-06637. [Online]. Available: <https://publications.rwth-aachen.de/record/1038622>