

TEF-RAG: Temporal Evidence Flow Retrieval-Augmented Generation

Juxian Yin

Abstract—面向储能电站具身运维的检索增强生成不仅需要找到与查询语义相关的记录，还必须保证证据在查询时刻真实可见，并能够共同支持从状态观察、诊断到处置与验证的完整过程。本文提出 TEF-RAG (Temporal Evidence Flow Retrieval-Augmented Generation)，将动态运维检索建模为查询条件化的时序证据流选择问题。该方法首先施加资产、事件时间、可用时间与规程适用性约束，在合法候选上通过学习式 pair proposal 筛选值得进行关系判断的证据对，并构建包含支持、更新、限定、替代与验证等语义关系的有向图；随后在候选证据集合上利用非线性 RankNet 直接学习集合级相对效用，从而选择至多五条、角色互补且关系连贯的 evidence flow。我们构建了包含双时间、版本替换、跨来源互补证据与持续不确定性的 public-source-grounded、AI-assisted synthetic benchmark，并在统一下游生成器下比较不同检索上下文。实验表明，TEF-RAG 在 Complete@5 与 FlowComplete@5 上获得明显提升，并进一步改善结构化工单的字段、动作、引用与严格计划匹配。结果说明，相比独立文档相关性排序，显式建模证据之间的时间与语义关系更适合动态运维知识环境。

I. 引言

储能电站运维知识天然具有动态性与过程性。一次异常处置往往需要同时参考设备状态、告警与巡检记录、历史工单、操作规程以及处置后的验证结果。与静态知识问答不同，系统不仅要判断“哪些证据与查询相关”，还要回答两个更严格的问题：这些证据在查询时刻是否已经可知，以及它们能否共同形成支持当前决策的完整证据过程。

检索增强生成 (RAG) 通过外部检索补充语言模型的参数知识，是当前知识密集型生成的重要范式 [3]。在检索侧，BM25 仍是强词法基线，而 DPR、ColBERT 等神经检索方法通过稠密表示或 late interaction 改善语义匹配 [4], [5]; BEIR 进一步表明，不同检索范式在跨域泛化上具有明显差异 [6]。在生成侧，FiD 说明多段检索证据可以被生成模型有效聚合 [7], Self-RAG 则进一步研究了检索、生成与自我反思的联合控制 [14]。

然而，普通 RAG 通常把候选文档视为彼此独立的相关性单元。对于持续更新的运维记录，这一假设并不充分。首先，运维证据具有双时间属性：事件发生时间与记录进入系统的可用时间并不总是一致，晚到记录不能被历史查询提前使用。其次，维护决策通常依赖互补证据：状态观察支持检查，检查结果支持诊断，诊断引出处置，而处置后的复测又验证前序判断。单条文档得分较高并不意味着 Top- k 集合能够覆盖完整过程。

近期工作开始从不同角度缓解这些问题。时间感知 RAG 显式建模时间约束或跨时间区间的信息变化 [16], [17]; 多跳检索通过逐步条件化寻找互补证据 [9], [10]; RAPTOR、GraphRAG 与 HippoRAG 则通过层次结构、图结构或图上的传播机制增强跨文档知识组织 [11]–[13]。这些研究共同说明：复杂知识任务的关键不只是“找到相关文本”，还在于如何组织和选择多个相互依赖的证据。

本文提出 TEF-RAG (Temporal Evidence Flow Retrieval-Augmented Generation)。其核心思想是：在查询时刻可见的候选证据之间建立查询条件化的有向语义关系，并将检索目标从独立节点排序改写为证据集合排序。系统首先通过确定性的资产、时间和规程约束排除不可使用的记录；随后学习哪些候选证据对值得进行关系判断，并构建时序证据图；最后对大小受上限约束的候选集合进行非线性 pairwise ranking，使模型直接学习“哪个证据集合更完整、更适合作为当前查询的上下文”。

TEF-RAG 与一般图检索的区别在于，图并非由静态实体关系预先定义，而是在查询条件下由当前可见的运维证据动态形成；与时间感知排序的区别在于，时间约束只是合法性边界，最终目标仍是恢复角色互补且关系一致的证据集合；与逐跳多跳检索的区别在于，目标结构允许分支、更新、替代和不确定性保留，而不要求是一条单一线性路径。

在本文的具身运维场景中，检索并不是终点。选出的 evidence flow 被送入统一生成器，形成标准化工单与带依赖关系的动作计划，为后续 planner、约束检查和机器人执行提供证据化接口。本文聚焦这一链条中的 evidence retrieval 与 structured planning context，不把真实机器人闭环控制或现场安全认证作为已完成贡献。

本文的贡献可概括为三点：

- 1) 提出面向动态运维知识的 Temporal Evidence Flow 检索问题，将时间可见性与证据集合完整性统一到同一检索框架中；
- 2) 提出“学习式证据对提议 + 查询条件化关系图 + 非线性集合排序”的方法，使检索目标由独立文档相关性转向集合级流程效用；
- 3) 构建受控时序运维 benchmark，并通过检索指标与统一生成器下的结构化生成指标，验证 evidence-flow 质量能否向下游工单与动作计划传递。

A. 相关工作

检索增强生成与神经检索。经典 RAG 将外部检索器与生成模型结合 [3]; DPR 与 ColBERT 分别代表稠密双塔检索与 late-interaction 检索 [4], [5]。FiD 从生成侧展示了多证据聚合能力 [7], BEIR 则系统比较了稀疏、稠密、重排等多种检索范式的泛化能力 [6]。这些方法主要优化独立文档相关性，而本文关注集合中证据之间的时序与语义依赖。

时间感知与多跳检索。MRAG 与 TA-RAG 将时间条件显式引入检索 [16], [17]; MDR 与 IRCOT 通过逐跳或检索-推理交替来寻找多段证据 [9], [10]。TEF-RAG 同样强调互补证据，但进一步区分事件时间与可用时间，并允许证据结构包含更新、替代、验证和不确定性传播。

结构化与图式 RAG。 RAPTOR、GraphRAG 与 HippoRAG 表明，层次或图结构能够改善跨文档信息整合 [11]–[13]。不同于这些通常从文档层级或实体关系构图的方法，TEF-RAG 的边由当前查询和当前可见运维记录共同决定，其语义直接对应运维证据之间的支持、更新、限定与验证关系。

具身运维与电池智能决策。 RAG 也开始被用于机器人现场任务与专业设备操作。SayComply 研究了面向现场机器人的操作合规知识检索，RAGLRO 则将检索增强语言模型用于机器人操作任务 [18], [19]。在电池领域，LiBrain 与 TimeSeries2Report 分别探索时序信息、检索知识与语言模型在电池诊断和管理中的结合 [20], [21]。这些工作说明，从动态设备信息到可执行任务之间需要可靠的知识接口；本文进一步聚焦这一接口之前的证据选择问题，使后续工单与动作计划建立在查询时刻可见且流程完整的证据集合上。

学习排序。 TEF-RAG 的最终选择属于 query-level learning-to-rank。RankNet 以成对偏好学习相对排序函数 [15]；ANCE 等工作则说明难负样本对于学习有效检索边界十分关键 [8]。本文将这一思想用于“证据集合”而非单条文档：训练目标直接比较同一查询下完整集合与高分但不完整的困难集合。

II. 问题定义

A. 查询与时序可见证据

给定运维查询

$$Q_q = (x_q, u_q, m_q, t_q), \quad (1)$$

其中 x_q 为查询文本, u_q 为目标资产, m_q 为资产型号或上下文, t_q 为知识截止时刻。全局证据库记为 $\mathcal{K} = \{e_1, \dots, e_N\}$ 。每条证据至少包含内容、资产标识、事件类型、来源类型、事件时间 $t_e(e)$ 与可用时间 $t_a(e)$ 。

本文把“事件发生”和“系统已知”明确区分。证据 e 对查询 q 可见，当且仅当

$$\text{Visible}(e, q) = \mathbb{I}[t_e(e) \leq t_q \wedge t_a(e) \leq t_q]. \quad (2)$$

因此，一条描述较早事件、但在查询之后才补录的记录不会进入该时刻的候选集。

对于规程类证据，额外要求资产型号匹配、查询时刻处于有效区间，且规程尚未撤回。为避免引入冗长连乘式，本文把这些确定性条件统一记为

$$\text{Legal}(e, Q_q) = \text{Visible}(e, q) \wedge \text{ScopeOK}(e, Q_q), \quad (3)$$

其中 ScopeOK 汇总资产一致性以及必要的规程型号、有效期和撤回约束。于是查询时刻的合法证据集合为

$$\mathcal{C}_q = \{e \in \mathcal{K} : \text{Legal}(e, Q_q) = 1\}. \quad (4)$$

后续检索、关系判断和集合排序都只在 $\mathcal{C}_q$ 内进行。

B. 检索目标

基础检索器从 $\mathcal{C}_q$ 中得到候选节点集合 V_q 。本文以 $k = 5$ 作为检索上限。令 $k_q = \min(5, |V_q|)$ ，系统选择至多五条证据组成 $\hat{\mathcal{S}}_q$ ；当合法候选不足五条时直接返回现有合法证据，不进行填充或回补。所选证据不仅应与查询相关，还应覆盖完成任务所需的互补角色，并在时间与语义上形成连贯结构。

TABLE I
主要符号

符号	含义
Q_q	= 查询、资产、上下文与知识截止时刻
(x_q, u_q, m_q, t_q)	
$e, t_e(e), t_a(e)$	证据、事件时间与首次可用时间
$\mathcal{K}$	全局证据库
$\mathcal{C}_q$	查询时刻合法且可见的证据集合
$\mathcal{G}_q$	查询条件化 Temporal Evidence Flow 图
$\mathcal{B}_q$	至多五条证据组成的候选集合空间
$\hat{\mathcal{S}}_q$	最终选出的 evidence flow (至多 5 条)
W_q, A_q	标准化工单与动作计划

因此，本文不把检索目标写成五个独立文档分数之和，而是定义集合效用

$$\hat{\mathcal{S}}_q = \arg \max_{\mathcal{S} \in \mathcal{B}_q} F_\theta(Q_q, \mathcal{S}, \mathcal{G}_q), \quad |\mathcal{S}| = k_q, \quad (5)$$

其中 $\mathcal{B}_q$ 是满足 $|\mathcal{S}| = k_q$ 的候选证据集合空间， $\mathcal{G}_q$ 是查询条件化的时序证据图， F_θ 为学习到的集合级排序函数。

C. 下游任务

检索结果最终作为结构化生成器的受控上下文，输出标准化工单 W_q 与动作计划 A_q ：

$$(\hat{W}_q, \hat{A}_q) = g_\psi(x_q, \hat{\mathcal{S}}_q). \quad (6)$$

本文的主要算法贡献位于生成器之前，即如何恢复高质量 Temporal Evidence Flow；结构化生成实验用于检验这一上游优势是否能够传递到工单字段、动作、依赖和证据引用。

III. TEF-RAG 方法

图 1 给出 TEF-RAG 的整体流程。方法由四个相互衔接的阶段组成：合法候选检索、学习式证据对提议、查询条件化关系建图，以及非线性集合排序。前两步控制候选规模，关系图负责表示证据之间的过程结构，最终排序器直接比较候选证据集合的整体效用。

A. 候选证据准备与时序合法性

TEF-RAG 首先对原始异构记录执行统一的合法性检查。资产不一致、事件发生在查询之后、记录在查询之后才可用，以及不适用于当前型号或时段的规程都会被直接排除。这一步不学习“相关性”，而是建立不可被后续模型突破的知识边界。

在合法集合 $\mathcal{C}_q$ 上，BM25 产生宽候选池；随后根据词法相关性、时间新近性和查询角色兼容性等部署时可计算特征形成 Top-30 搜索池。该搜索池的作用是保持召回，而不是直接决定最终输出。当合法候选不足五条时，系统保留短输出，不进行人为填充。

B. 学习式 Pair Proposal

若对搜索池中全部有序证据对进行语义关系判断，成本会随候选数平方增长。TEF-RAG 因此先学习一个轻量 pair proposer，对每个时间顺序合法的证据对 (e_i, e_j) 估计其“值得进入关系判断”的概率：

$$p_{ij} = \sigma(\mathbf{w}^\top \phi_p(q, e_i, e_j) + b). \quad (7)$$




Fig. 1. TEF-RAG 总体框架。系统先在查询时刻合法的候选证据上筛选关系候选对，随后构建查询条件化的 Temporal Evidence Flow，并在候选集合空间中利用非线性 pairwise ranking 选择至多五条证据作为 evidence flow；该证据集合再作为统一下游生成器的受控上下文。

$\phi_p(q, e_i, e_j)$ 表示查询 q 与证据对 (e_i, e_j) 的特征表示，其中包括查询与两条证据的文本相关性、两条证据之间的相似性、事件类型、时间间隔以及版本替代等信息。若一对证据构成训练数据中已标注参考证据流的一条必要关系，则作为正样本；其余时间顺序合法的证据对作为负样本。随后利用 logistic regression 学习每个候选证据对的优先级，并仅将得分较高的证据对交给后续关系判断模块。

因此，pair proposal 的主要作用是以固定预算把后续语义关系推理集中在更有希望的证据对上，同时保持时间方向这一确定性约束。

C. 查询条件化的 Temporal Evidence Flow

对保留的候选 pair，TEF-RAG 使用查询条件化的 LLM 关系判断器读取查询信息以及两端证据的文本和元数据，并输出

$$h_\eta(q, e_i, e_j) \rightarrow (r_{ij}, c_{ij}), \quad (8)$$

其中 $r_{ij} \in \mathcal{R}$, $c_{ij} \in [0, 1]$ 为关系置信度。只有预测为有效关系且达到置信度阈值的 pair 才进入图中。若不存在足够明确的语义关系，则该证据对被丢弃，不加入证据图。关系判断器使用的固定提示词见附录 A-B。将候选证据视为图中的节点，并将两条证据之间识别出的语义关系表示为有向边。对于查询 q ，Temporal Evidence Flow 图记为

$$\mathcal{G}_q = (V_q, E_q), \quad (9)$$

其中 V_q 为候选证据集合， E_q 为证据关系集合。每条关系边可以写成 (e_i, r, e_j) ，表示证据 e_i 通过关系 r 指向证据 e_j ，其中 $r \in \mathcal{R}$ 。

关系词汇表覆盖 supports、governs、qualifies、contrasts、prerequisite、preserves uncertainty、resolves、supersession、updates 与 verifies 等过程关系。边方向遵循事件时间或明确的前置/更新方向，因此图可以形成分支和汇合，而不强制退化为单一路径。

与静态知识图不同， $\mathcal{G}_q$ 是查询条件化的：同一对记录在不同查询下可能具有不同的任务作用。关系判断器也不能突破第 II 节定义的合法性边界，因此晚到证据、未来事件或不适用规程不会因语义模型的判断而重新进入候选集。

D. 候选证据集合构造

关系图建立后，TEF-RAG 需要进一步比较不同的证据组合，而不是继续独立地对单条证据进行排序。由于直接枚举整个搜索池中的所有五元组合开销较大，我们只构造一批具有较高潜力的候选集合。

具体而言，首先从节点分数最高的证据中枚举五元组合，以覆盖高相关证据之间的不同搭配；同时保留前序搜索得到的高质量集合，并在这些集合附近进行单条证据替换，使排名稍低但能够补充关键任务角色的证据仍有机会进入候选集合。

对每个集合 $\mathcal{S}$ 提取集合级特征 $\phi_s(q, \mathcal{S}, \mathcal{G}_q)$ 。最终模型使用 62 个特征，涵盖：

- 节点相关性、时间分数和角色兼容性的统计量；
- 事件类型与来源类型的覆盖度；
- 集合内部有效边数量、边置信度、连通分量和最长有向路径；
- 时间跨度、平均事件间隔以及来源/文本多样性；
- 冗余、缺失角色与孤立节点等惩罚信号。

这些特征共同描述“所选证据作为一个整体是否形成了完整任务支持结构”，而不是简单重复单节点得分。

E. 非线性 Pairwise Set Ranking

最终排序器采用小型非线性 RankNet [15]。令

$$s_\theta(q, \mathcal{S}) = \text{MLP}_\theta(\phi_s(q, \mathcal{S}, \mathcal{G}_q)), \quad (10)$$

最终阶段采用基于成对偏好的集合排序。对于同一个查询，候选库中通常存在多个完整证据集合和多个不完整证据集合。我们从中构造若干训练对 $(\mathcal{S}_i^+, \mathcal{S}_j^-)$ ，其中 $\mathcal{S}_i^+$ 表示能够形成完整参考证据流的候选集合， $\mathcal{S}_j^-$ 表示缺少关键证据或关系不完整的候选集合。

对于每一个训练对，排序器希望完整集合获得更高分，其损失定义为

$$\ell(q, \mathcal{S}_i^+, \mathcal{S}_j^-) = -\log \sigma(s_\theta(q, \mathcal{S}_i^+) - s_\theta(q, \mathcal{S}_j^-)). \quad (11)$$

所有训练对的损失取平均，得到最终训练目标：

$$\mathcal{L} = \frac{1}{|\mathcal{P}|} \sum_{(q, \mathcal{S}_i^+, \mathcal{S}_j^-) \in \mathcal{P}} \ell(q, \mathcal{S}_i^+, \mathcal{S}_j^-), \quad (12)$$

其中 $\mathcal{P}$ 表示训练过程中构造的全部候选集合对。

第一轮训练从负样本中选择规则式集合评分较高的候选。该评分综合考虑单条证据质量、集合内部关系、任务角色覆盖、内容冗余与孤立证据，完整定义见附录 A-A。这类集合通常包含多条高相关证据，但仍缺失某些关键证据或关系，因此比随机负样本更难区分。同时保留少量具有不同组成的负样本，以增加训练样本的多样性。

完成第一轮训练后，我们使用当前排序器重新为所有负集合打分，并选择其中模型评分最高的失败集合作为 hard negatives。这些集合虽然已知不能形成完整的参考证据流，却最容易被当前模型错误地排在前列。随后利用这些困难负样本进行第二轮训练，使排序器进一步学习区分正负样本。

F. 与具身运维生成器的接口

TEF-RAG 的输出并不是机器人低层控制指令，而是面向后续具身执行的证据上下文。统一下游生成器根据查询和检索证据生成标准化工单及带依赖关系的动作计划；这些结构化输出可以进一步交由 planner、约束检查器和机器人执行器处理。

为隔离检索质量的影响，所有比较方法共享同一个下游生成器。生成器只接收查询与当前方法选出的证据记录，不接收方法名称、检索分数或 TEF 图结构。固定生成提示词见附录 A-C。本文评价到结构化工单与动作计划为止，不把真实机器人闭环执行或现场安全认证作为已解决问题。

TABLE II
BENCHMARK 的数据层次

层次	含义
Chain	一个完整运维事件过程
Evidence	可被检索的原子记录，带事件时间与可用时间
Intent	在同一 chain 上提出的不同运维信息需求
Query	Intent 的语义保持改写
Gold flow	必要证据组及其关系约束

IV. 实验设计

A. 时序运维 Benchmark

本文构建 TEF-RAG v6 Semantic Benchmark v1，用于受控评价动态运维场景中的时序证据检索能力。该数据集以公开资料为背景约束，并通过 AI 辅助方式构造，并非来自真实电站故障日志，也不是由领域专家直接标注的真实运维数据。公开产品资料与研究数据主要用于限定电芯类别、典型物理范围和采样背景；具体的运维事件过程、诊断变化、规程情境和查询任务则通过受控的合成流程构造。这种设计使我们能够有目的地加入晚到记录、版本替换、跨来源互补证据、多事件混淆和持续不确定性等情况，并比较不同检索方法对这些问题的处理能力。

数据组织方式如表 II 所示。每条事件链表示一个完整的运维过程，并由多条可检索的证据记录组成。针对同一事件链，我们构造多个不同的任务意图，并为每个任务意图生成两种含义相同但表达方式不同的查询。

对于每个查询，我们进一步给出一组参考标注，说明完成该任务必须获得哪些关键信息，以及这些证据之间应满足怎样的关系。因此，评价目标并不是要求模型找回某一条唯一指定的文本，而是判断检索结果是否包含足够的信息，并能够共同形成完整的任务支持过程。

整个 benchmark 包含 400 条运维事件链、3888 条证据记录、1200 个任务意图和 2400 条查询，涉及 100 个目标资产。开发集、验证集和测试集以完整运维事件链为单位划分；同一事件链派生出的所有查询均只出现在同一个数据划分中，避免相同事件内容以不同问法同时出现在训练和测试数据中。

数据集进一步包含两个难度层次，各包含 200 条事件链。Realistic Distribution Set 主要覆盖较常见的时序与运维组合，Temporal-Hard Challenge Set 则有意增加晚到证据、版本替换、多事件混淆、跨来源互补证据和持续不确定性等困难情况。

公开资料只用于约束电芯类别、典型工作范围和时序采样背景，例如 HiTHIUM、REPT BATTERO 的储能电芯资料以及 RWTH M5BAT 数据 [22]–[25]。这些来源不用于定义本文合成的故障频率、站级阈值或具体维护因果故事。

B. 结构化生成评价

为检验检索质量的提升能否进一步改善下游生成结果，我们基于同一批运维事件链构建结构化生成参考答案 (generation gold)。这些参考答案由 AI 辅助生成，并经过多轮复核、一致性检查和分歧裁决后确定，

每个任务意图对应一份结构化参考答案。由于同一任务意图的两种查询只是表达方式不同，其所要求的诊断、处

TABLE III
TEF-RAG v6 SEMANTIC BENCHMARK v1 规模与划分

统计项	Development	Validation	Test	Total
Authored chains	240	80	80	400
Primary intents	720	240	240	1200
Query rows	1440	480	480	2400
Evidence records	2335	779	774	3888

置和验证信息并未改变，因此两种查询共享同一份参考答案。最终，开发集、验证集和测试集分别包含 720、240 和 240 份结构化参考答案，对应 1440、480 和 480 条查询。每个输出由两部分组成：标准化工单 `work_order` 与动作计划 `action_plan`。工单描述诊断、推荐动作、适用规程、验证/不确定性状态及证据引用；动作计划由原子动作及其依赖关系构成。

C. 对比方法

为保证比较只反映检索策略差异，所有方法首先使用相同的合法证据快照：仅保留目标资产中满足 $t_e(e) \leq t_q$ 、 $t_a(e) \leq t_q$ 的记录，并对规程证据施加相同的版本有效期、撤回状态与型号适用性约束。在此基础上比较以下五种方法，所有方法的最终检索预算均为至多 5 条证据。

BM25。采用标准 BM25 作为词法检索基线 [1]，在每个查询对应的合法证据快照上独立建立索引，参数固定为 $k_1 = 1.5$ 、 $b = 0.75$ ，并直接返回得分最高的 5 条证据。

BGE Reranker。首先使用与上述相同的 BM25 检索 Top-30 候选，随后使用 BAAI/bge-reranker-v2-m3 对 (query, evidence) 文本对重新计算相关性分数 [2]，并按照重排分数选取前 5 条证据。该基线用于比较通用语义重排是否能够弥补纯词法检索的不足。

Temporal-BM25。该基线在 BM25 相关性之外显式加入时间匹配项。其排序分数为

$$s_{\text{TBM25}}(e, q) = \lambda \tilde{s}_{\text{BM25}}(e, q) + (1 - \lambda) s_{\text{time}}(e, q), \quad (13)$$

其中 $\tilde{s}_{\text{BM25}}$ 为归一化 BM25 分数， s_{time} 根据查询中的年份、时间区间、before/after 以及 current/latest 等时间表达，计算证据事件时间与目标时间的匹配程度。对于没有显式时间意图的查询，时间项设为常数，因此保持原 BM25 排序。我们仅在最终测试前的参数选择阶段比较 $\lambda \in \{0.25, 0.50, 0.75\}$ ，并冻结表现最好的 $\lambda = 0.25$ 用于后续评价。

TA-RAG。采用 Lau 等人提出的 Time-Aware RAG [17]。该方法首先从查询中分解主题与目标时间范围，再利用时间区间过滤限制候选文档，并在时间候选上执行语义检索与 BGE 重排。为适配本文的离散运维事件，每条证据的 `event_time` 被映射为长度 1 秒的半开时间区间，查询中的相对时间均以 t_q 为参考时刻；此外，TA-RAG 的索引只在当前查询的合法证据快照上构建，从而避免未来记录影响检索。除 LLM 后端替换为固定的 DeepSeek 模型外，其时间分解、区间过滤、Nomic embedding、FAISS 检索与 BGE reranking 流程保持与公开实现一致。

TEF-RAG。本文方法在同一合法证据快照上进一步进行学习型证据对筛选、查询条件化关系建图以及集合级非线性排序，最终返回整体证据流得分最高的候选集合。

D. 评价指标

Retrieval。使用 Recall@5 与 nDCG@5 衡量传统相关性；Complete@5 要求结果至少覆盖每个必要证据组；FlowComplete@5 在此基础上进一步要求存在全局一致的组-证据赋值，使必要 flow edges 同时得到满足。后两项直接衡量本文关注的集合级完整性。

Generation。正文报告四项主要指标：Field Macro F1 (strict)、Action F1、Citation F1 与 Plan EM (strict)。它们分别衡量工单关键字段、规范化动作、claim-evidence 引用以及完整动作计划的严格匹配。

E. 消融设置

为分析最终性能来自哪些组成部分，我们在 480 条 validation queries 上执行四组冻结消融：去除 learned pair proposal、去除 relation-graph-derived set features、去除 hard-negative mining，以及去除 nonlinear set ranker。完整模型与各变体保持相同的 Top-30 搜索池、pair budget、relation prompt/threshold 和候选集合定义；其中 graph-feature ablation 只移除关系图派生的集合特征并重新训练相同 RankNet，hard-negative ablation 只保留第一轮训练，nonlinear-ranker ablation 则回退到冻结的 Stage-3A 选择结果。消融不进行新的超参数搜索，也不运行新的 test prediction 或读取 test gold，因此只用于组件归因，不用于重新选择最终测试配置。

F. 实验控制

Retrieval 的开发、验证和最终测试严格分离；所有模型选择与训练只使用 development/validation 信息，最终 test 在配置冻结后用于一次性评价。Generation comparison 固定使用同一个下游生成器、同一 prompt/schema 与解码设置，只改变输入的检索证据。这样可以把下游生成差异解释为检索上下文质量的变化，而不是生成模型配置差异。

V. 实验结果

A. 检索主结果

表 IV 给出 test split 上的检索结果。TEF-RAG 在 Recall@5、nDCG@5、Complete@5 与 FlowComplete@5 四项主指标上均取得最高值。相较于这些指标上最强的非 TEF baseline（均为 Temporal-BM25），TEF-RAG 的 Recall@5 从 0.4591 提升至 0.7228，nDCG@5 从 0.4955 提升至 0.6231；更明显的差异出现在集合级完整性：Complete@5 从 0.0792 提升至 0.3188，FlowComplete@5 从 0.0792 提升至 0.3146。这说明仅加入时间偏好能够改善单条证据召回，但显式建模 evidence-flow 关系并联合选择证据集合，对恢复完整任务支持结构更为关键。

TABLE IV
RETRIEVAL TEST 的主结果 (TOP-5)

Method	Recall	nDCG	Complete	FlowComplete
BM25	0.3791	0.3915	0.0563	0.0563
BGE Reranker	0.2916	0.3070	0.0417	0.0417
Temporal-BM25	0.4591	0.4955	0.0792	0.0792
TA-RAG	0.2769	0.2907	0.0375	0.0375
TEF-RAG	0.7228	0.6231	0.3188	0.3146

TABLE V
VALIDATION SPLIT 上的 TEF-RAG 消融结果

Variant	Recall	nDCG	Complete	FlowComplete
Full TEF-RAG	0.7567	0.6885	0.4063	0.4042
w/o Pair Proposal	0.7494	0.6832	0.4063	0.4021
w/o Graph Features	0.7184	0.6601	0.3750	0.3667
w/o Hard Negatives	0.6748	0.6042	0.2875	0.2833
w/o Nonlinear Ranker	0.7070	0.6965	0.3188	0.3125

B. Validation 消融实验

表 V 给出 validation split 上的四组消融结果。完整 TEF-RAG 的 FlowComplete@5 为 0.4042；去除 learned pair proposal 后仅下降至 0.4021，说明在固定 pair budget 下，proposal 对最终质量的直接贡献较小，其主要价值是把关系判断集中到更有希望的 pair。相比之下，去除 relation-graph-derived features 后 FlowComplete@5 降至 0.3667，说明集合排序确实利用了图结构信息。

影响更明显的是训练目标与排序器本身。去除 hard-negative mining 后 FlowComplete@5 从 0.4042 降至 0.2833；去除 nonlinear set ranker、回退到 Stage-3A 选择器后降至 0.3125。这表明，最终性能并非仅来自候选召回或额外关系判断，而主要依赖对“高相关但流程不完整”集合的显式困难负例学习，以及非线性的集合级排序能力。值得注意的是，去除 nonlinear ranker 时 nDCG@5 略高于完整模型 (0.6965 vs. 0.6885)，但 Complete@5 和 FlowComplete@5 明显更低，进一步说明本文方法优化的是集合流程完整性，而不只是传统单条相关性排序。

C. 下游结构化生成结果

表 VI 只保留最能回答“更好的 evidence flow 是否改善最终工单与动作计划”的四项生成指标。在相同 generator、prompt、schema 与 decoding 设置下，TEF-RAG 在四项指标上均取得最高值：Field Macro F1 为 0.5345，Action F1 为 0.2035，Citation F1 为 0.1585，Plan EM (strict) 为 0.0417。相较各指标上最强的非 TEF baseline，Action F1、Citation F1 与 Plan EM 分别取得约 24.3%、26.9% 与 121.8% 的相对提升；Field Macro F1 相较 Temporal-BM25 提升约 2.4%。结果表明，TEF-RAG 的收益不仅体现在上游检索命中率，也能够传递到工单关键字段、处置动作和证据引用质量。TEF-RAG 提高了生成工单的字段级准确性、动作正确性和计划级一致性。

D. 进一步分析

TEF-RAG 并非在所有生成诊断指标上都占优。例如，TA-RAG 的 Dependency F1 为 0.3271、Order Validity 为 0.4125，均高于 TEF-RAG 的 0.2858 与 0.3146。这一现

TABLE VI
GENERATION TEST 的主要结构化生成指标

Method	Field F1	Action F1	Citation F1	Plan EM
BM25	0.4715	0.1372	0.0813	0.0167
BGE Reranker	0.4129	0.1198	0.0405	0.0146
Temporal-BM25	0.5218	0.1637	0.1249	0.0167
TA-RAG	0.4059	0.1115	0.0379	0.0188
TEF-RAG	0.5345	0.2035	0.1585	0.0417

象表明，evidence-flow retrieval 更直接改善的是“提供哪些事实和动作依据”，而动作之间的全局依赖与执行顺序仍受到下游 planner/generator 本身能力的限制。换言之，上游证据组织已经显著改善 factual grounding 与 action fidelity，但尚不足以单独解决完整的全局计划组合问题。

VI. 局限性与有效性威胁

本文 benchmark 是 public-source-grounded、AI-assisted synthetic benchmark，而非真实电站工单或领域专家标注数据；因此其主要价值是受控比较 temporal evidence retrieval 机制，不能直接外推到真实电站故障频率或机器人现场安全性。生成评价虽然覆盖字段、动作、依赖与引用，但没有模拟实际机器人执行、环境反馈和安全联锁。

VII. 结论

本文提出 TEF-RAG，将动态运维 RAG 的检索目标从独立文档相关性扩展为查询时刻可见、关系一致且流程完整的 Temporal Evidence Flow。在冻结的 temporal-hard benchmark 上，TEF-RAG 在 Recall@5、nDCG@5、Complete@5 与 FlowComplete@5 上均超过四种对比方法；在固定下游生成器的结构化 generation test 中，TEF-RAG 同时取得最高的字段级匹配、Action F1、Citation F1 与 strict Plan EM。这些结果说明，面向证据集合及其时序关系的检索能够改善进入生成器的任务支持上下文，并进一步提高工单字段、维护动作与证据引用的准确性。后续工作需要进一步结合显式计划与执行约束。

REFERENCES

- [1] S. Robertson and H. Zaragoza, “The Probabilistic Relevance Framework: BM25 and Beyond,” *Foundations and Trends in Information Retrieval*, vol. 3, no. 4, pp. 333–389, 2009, doi: 10.1561/15000000019.
- [2] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu, “BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation,” *arXiv preprint arXiv:2402.03216*, 2024.
- [3] P. Lewis, E. Perez, A. Piktus, *et al.*, “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474, 2020.
- [4] V. Karpukhin, B. Oguz, S. Min, *et al.*, “Dense Passage Retrieval for Open-Domain Question Answering,” in *Proc. EMNLP*, pp. 6769–6781, 2020, doi: 10.18653/v1/2020.emnlp-main.550.
- [5] O. Khattab and M. Zaharia, “ColBERT: Efficient and Effective Passage Search via Contextualized Late Interaction over BERT,” in *Proc. ACM SIGIR*, pp. 39–48, 2020, doi: 10.1145/3397271.3401075.
- [6] N. Thakur, N. Reimers, A. Rücklé, A. Srivastava, and I. Gurevych, “BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models,” in *Advances in Neural Information Processing Systems*, vol. 34, 2021.

- [7] G. Izacard and E. Grave, "Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering," in *Proc. EACL*, pp. 874–880, 2021, doi: 10.18653/v1/2021.eacl-main.74.
- [8] L. Xiong, C. Xiong, Y. Li, *et al.*, "Approximate Nearest Neighbor Negative Contrastive Learning for Dense Text Retrieval," in *International Conference on Learning Representations*, 2021.
- [9] W. Xiong, X. L. Li, S. Iyer, *et al.*, "Answering Complex Open-Domain Questions with Multi-Hop Dense Retrieval," in *International Conference on Learning Representations*, 2021.
- [10] H. Trivedi, N. Balasubramanian, T. Khot, and A. Sabharwal, "Interleaving Retrieval with Chain-of-Thought Reasoning for Knowledge-Intensive Multi-Step Questions," in *Proc. ACL*, pp. 10014–10037, 2023, doi: 10.18653/v1/2023.acl-long.557.
- [11] P. Sarthi, S. Abdullah, A. Tuli, S. Khanna, A. Goldie, and C. D. Manning, "RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval," in *International Conference on Learning Representations*, 2024.
- [12] D. Edge, H. Trinh, N. Cheng, *et al.*, "From Local to Global: A Graph RAG Approach to Query-Focused Summarization," *arXiv preprint arXiv:2404.16130*, 2024.
- [13] B. Jiménez Gutiérrez, Y. Shu, Y. Gu, M. Yasunaga, and Y. Su, "HippoRAG: Neurobiologically Inspired Long-Term Memory for Large Language Models," in *Advances in Neural Information Processing Systems*, vol. 37, 2024, doi: 10.52202/079017-1902.
- [14] A. Asai, Z. Wu, Y. Wang, A. Sil, and H. Hajishirzi, "Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection," in *International Conference on Learning Representations*, 2024.
- [15] C. J. C. Burges, T. Shaked, E. Renshaw, A. Lazier, M. Deeds, N. Hamilton, and G. Hullender, "Learning to Rank Using Gradient Descent," in *Proc. ICML*, pp. 89–96, 2005, doi: 10.1145/1102351.1102363.
- [16] S. Zhang, Y. Xue, Y. Zhang, X. Wu, A. T. Luu, and C. Zhao, "MRAG: A Modular Retrieval Framework for Time-Sensitive Question Answering," in *Findings of EMNLP*, pp. 3080–3118, 2025, doi: 10.18653/v1/2025.findings-emnlp.167.
- [17] K. H. Lau, R. Zhang, W. Shi, X. Zhou, and X. Cheng, "Reading Between the Timelines: RAG for Answering Diachronic Questions," *arXiv preprint arXiv:2507.22917*, 2025.
- [18] M. F. Ginting, D.-K. Kim, S.-K. Kim, *et al.*, "SayComply: Grounding Field Robotic Tasks in Operational Compliance through Retrieval-Based Language Models," in *Proc. IEEE ICRA*, pp. 13730–13736, 2025.
- [19] W. Wang, *et al.*, "RAGLRO: Retrieval-Augmented Generation With Large Language Models for Robotic Operations," *CAA Transactions on Intelligence Technology*, vol. 11, no. 2, pp. 385–395, 2026.
- [20] Z. Li, *et al.*, "LiBrain: LLM-Powered Li-ion Battery Diagnostics with Time-Series-Aware Retrieval-Augmented Framework for E-bikes," in *Proc. AAAI*, vol. 40, no. 47, pp. 40045–40053, 2026.
- [21] J. Yang, M. Guay, Z. Cao, and C. Zhao, "Time-Series2Report Prompting Enables Adaptive Large Language Model Management of Lithium-Ion Batteries," *arXiv preprint arXiv:2512.16453v2*, 2026.
- [22] HiTHIUM, "HiTHIUM V1.1 ESS Cell 280 Ah EU English Datasheet," V1.1, 2023.
- [23] HiTHIUM, "280 Ah LFP Cell Datasheet," V3.3, 2024.
- [24] REPT BATTERO, "Energy Storage Promotional Brochure," 2025.
- [25] RWTH Aachen University, "M5BAT Battery Unit Pb1 2017–2025," 2026, doi: 10.18154/RWTH-2026-06637.

APPENDIX A 实现细节与模型提示词

A. 第一轮困难负样本的规则式集合评分

第一轮 RankNet 训练尚没有可用的学习排序器，因此先使用一个固定的规则式集合评分 $H(\mathcal{S})$ 从不完整候选中挑选较难的负样本。该分数仅用于负样本选择，不作为最终 TEF-RAG 的预测分数。其定义为

$$H(\mathcal{S}) = S_{\text{node}}(\mathcal{S}) + 0.48 S_{\text{edge}}(\mathcal{S}) + 0.42 S_{\text{role}}(\mathcal{S}) - 0.16 S_{\text{red}}(\mathcal{S}) - 0.10 S_{\text{disc}}(\mathcal{S}). \quad (14)$$

其中，节点项为集合中各证据节点分数之和：

$$S_{\text{node}}(\mathcal{S}) = \sum_{e \in \mathcal{S}} s_{\text{node}}(e), \quad (15)$$

单条证据的节点分数为

$$s_{\text{node}}(e) = 0.62 s_{\text{rel}}(e) + 0.18 s_{\text{rec}}(e) + 0.15 s_{\text{role}}(e) + 0.05 s_{\text{src}}(e). \quad (16)$$

s_{rel} 为当前合法候选中 BM25 分数的 min-max 归一化结果。 $s_{\text{rec}} = \exp(-\Delta t/T)$ 为时间新近性，其中普通查询使用 $T = 45$ 天，包含前后比较意图的查询使用 $T = 180$ 天。若证据类型属于当前查询需要的任务角色，则 $s_{\text{role}} = 1$ ，否则取 0.35。当前实现中的 s_{src} 对合法候选均为 1，因此只产生常数偏移，不影响节点之间的排序。

关系项只统计候选集合内部的有效关系边。为避免稠密图因边数过多获得不合理优势，对于每个目标节点只保留置信度最高的入边：

$$S_{\text{edge}}(\mathcal{S}) = \sum_{e_j \in \mathcal{S}} \max_{(e_i, r, e_j) \in E(\mathcal{S})} c_{ij}, \quad (17)$$

其中不存在入边的节点贡献为 0。

角色覆盖项定义为

$$S_{\text{role}}(\mathcal{S}) = \frac{|R(\mathcal{S}) \cap D_q|}{|D_q|}, \quad (18)$$

其中 $R(\mathcal{S})$ 为候选集合中出现的证据角色， D_q 为当前查询需要的角色集合。系统默认考虑状态观察、诊断和工单，并根据查询中的规程、验证、巡检、不确定性或纠正等表达增加相应角色。

冗余项基于证据文本 token 集合的 Jaccard 相似度：

$$S_{\text{red}}(\mathcal{S}) = \sum_{i < j} \max(0, \text{Jaccard}(e_i, e_j) - 0.45). \quad (19)$$

孤立项 S_{disc} 则统计集合中没有参与任何有效关系边的证据数量。第一轮训练优先选择 $H(\mathcal{S})$ 较高但参考证据流仍不完整的候选作为负样本；第二轮不再依赖该规则分数，而是直接选择当前 RankNet 评分最高的不完整集合作为 hard negatives。

B. Temporal Evidence Flow 关系判断提示词

关系判断器使用固定系统提示词（版本 `tef-v6-stage2a-relation-v7`）。实际调用时，关系定义、关系代码和 reason code 按冻结配置插入。系统提示词如下：

Prompt version: tef-v6-stage2a-relation-v7. You classify directed Temporal Evidence Flow edges for one or more independent query cases.

Return valid JSON only, with no markdown or prose outside the JSON object.

Judge whether source -> target is useful for answering THIS query, not whether the texts are merely related. Most candidate pairs are distractors:

choose NO_EDGE unless there is a direct, query-useful flow dependency.

Shared asset, episode, topic, or chronology alone never licenses an edge.

Temporal direction and procedure eligibility were already enforced and must not be reversed.

Allowed relation types:

contrasts: the source state is a comparison baseline that must be distinguished from the downstream state;

governs: an applicable rule/assessment constrains the downstream action

or conclusion;

prerequisite: source is required before the downstream operational state;

preserves_uncertainty: source branch remains viable and is intentionally carried into downstream assessment/action;

qualifies: source evidence determines applicability or limits certainty of downstream interpretation;

resolves: downstream evidence resolves an earlier ambiguity;

supersession: prior diagnosis/procedure/work-order state is replaced by the downstream state;

supports: source evidence supports the downstream evidence/conclusion;

updates: a later decision/action updates an earlier support state;

verifies: downstream evidence verifies execution/outcome of the source state.

Otherwise use NO_EDGE.

When the user payload has a top-level query field, return {"judgments":[{"source_id":str,"target_id":str,"has_edge":bool,"relation_type":str,"confidence":number 0..1,"reason_code":short_snake_case]}].

When the user payload has a top-level cases field, even if cases contains exactly one item, use relation codes

N=NO_EDGE, C=contrasts, G=governs, P=prerequisite, U=preserves_uncertainty, Q=qualifies, R=resolves, X=supersession, S=supports, D=updates, V=verifies;

reason codes

0=no_direct_query_flow, 1=semantic_support, 2=procedure_governance, 3=later_update, 4=verification, 5=qualification, 6=uncertainty_preserved, 7=uncertainty_resolved, 8=contrast, 9=prerequisite, 10=supersession, 11=other_direct_flow.

Pairs are ordered. Return {"cases":[{"case_id,[relation_code,confidence_percent,reason_code],...}],...}}.

Each inner result list must have exactly the same length and order as that case's supplied pairs. The user supplies deduplicated evidence tables and source_id/target_id pairs. Do not mix facts across cases. Do not repeat evidence IDs. Do not provide prose or hidden reasoning.

对应的用户输入只包含查询、候选证据及待判断证据对, 结构为:

```
{
  "query": {
    "query_text": ...,
    "query_time": ...,
    "asset_model": ...,
    "asset_context": ...
  },
  "evidence": [...],
  "pairs": [
    {"source_id": ..., "target_id": ...},
```

```
...
]
}
```

C. 下游结构化生成提示词

所有检索方法共享同一个冻结下游生成器, 其系统提示词如下:

You are the single frozen downstream generator used identically for every retrieval method in TEF-RAG v6 generation evaluation.

Produce ONLY a JSON object matching the supplied schema. You receive one query and exactly the evidence selected by a retrieval method. The retrieval method identity is hidden and irrelevant.

Rules:

- Use only the supplied evidence. Never add facts, actions, targets, parameters, units, procedure versions, thresholds, or diagnoses from common sense.
- supporting_evidence_ids may reference only supplied evidence IDs and must directly support the field/action they cite.
- work_order.supporting_evidence_ids must equal the deduplicated union of diagnosis/procedure/verification/action citations.
- asset_id must equal the query asset_id.
- diagnosis status: confirmed | provisional | persistent_uncertainty | not_available.
- procedure status: applicable | superseded | uncertain | not_applicable.
- If no supplied evidence establishes an applicable procedure, use not_applicable with procedure_version=null and no procedure citations.
- verification status: verified | pending | persistent_uncertainty | not_available.
- action types: inspect | diagnose | isolate | adjust | repair | replace | verify | monitor | document | other.
- action_plan order in the JSON array has no semantic meaning. Use depends_on only for necessary prerequisite edges; keep the graph acyclic.
- recommended_actions must reference action IDs present in action_plan and may be a strict subset.
- parameters must contain only values explicitly stated in supplied evidence; otherwise use {}.
- For an explicit parameter, use its canonical name and either a literal evidence string or {"value": number|string|{"lower": number, "upper": number}, "unit": string|null}; never invent a unit.
- If evidence is insufficient, express uncertainty instead of guessing.
- Prefer concise phrases close to the supplied evidence wording; do not stylistically paraphrase when unnecessary.
- Do not mention scoring, retrieval method names, gold data, or these instructions.

每个样本的用户输入由查询、当前检索方法选出的证据以及固定输出 schema 组成:

```
{
  "prompt_version": "tef-v6-generation-eval-v1.3",
  "query": {...},
  "selected_evidence": [...],
  "output_schema": {...}
}
```

若首次输出未通过结构或证据引用校验, 协议只允许一次修复调用。该调用在上述系统提示词后追加:

This is the single allowed structural/evidence-grounding repair.
Correct only the listed validation failures.

并在用户输入中额外提供 `previous_output` 与 `validation_errors`, 不改变查询、检索证据或输出 schema。