

TMC-RAG：面向储能电站运维任务规划的 时序感知多源约束检索增强生成

Juxian Yin*

Abstract

储能电站运维任务需要联合规程、历史工单、状态与预测证据，单一相似度排名难以同时满足设备、时间和规程适用性要求。本文提出时序感知多源约束检索增强生成方法（*Time-aware Multi-source Constrained Retrieval-Augmented Generation, TMC-RAG*），通过分源检索、查询时刻可见性过滤、型号与版本约束及整节恢复组织证据，生成结构化工单与依赖动作，并允许至多一次基于运行协议的修复。在 12 个合成开发事件的 48 条困难查询上，主方法必要证据召回宏平均为 86.11%，统一 BM25 为 46.70%；主方法未观察到错设备、错型号或无效规程，而所有方法共享的时间快照均未返回未来证据。以 *deepseek-v4-flash* 为基座生成模型时，修复后的主方法与仅分源路由对照均达到 48/48 字段联合正确和参考计划有效，但路由对照 44/48 条检索包仍含完整性问题。移除时间窗口或预测卡分别使最终字段或字段与计划降为 40/48；移除整节恢复使完整章节覆盖由 75% 降至 0，却未降低当前生成分数。冻结后的验证集与测试集各运行一次，各 48 条查询均在修复后通过字段、参考计划与任务协议检查。结果支持在当前原型中分开评价检索完整性、程序化任务完成和协议通过。

关键词：储能电站；检索增强生成；多源异构检索；时序可见性；层级文档；任务规划

1. 引言

电化学储能电站的运维知识分散在不同形态的数据系统中。设备说明书和安全规程通常按章、节、条组织，步骤的适用范围与前置条件依赖完整章节；历史工单和设备台账以关系型记录保存，设备编号、告警时间和处理状态等字段要求精确匹配；BMS 与 SCADA 状态则持续更新，同一事实是否可用于回答取决于数据产生时间、到达时间和查询截止时刻。面向巡检与故障处置的任务规划还需要输出具有依赖关系的动作，而不仅是自然语言答案。

经典 RAG 通过外部非参数记忆为生成模型提供可追溯知识，但其基本形式主要面向文本段落

检索 [1]。在工业机器人任务规划中，SayComply 使用层级化操作知识和树状检索支撑合规任务生成 [2]；RAGLRO 进一步将 RAG 用于电力开关柜机器人操作 [3]。在电池管理方面，LiBrain 将实时监测、专业预测模型与知识库增强相结合 [4]，Time-Series2Report 则把多变量电池时序转换为结构化语义报告 [5]。这些工作分别验证了层级操作知识、机器人任务规划及电池时序语义化的价值，但储能运维查询仍同时面临多源字段对齐、证据时间可见性和动作依赖三个问题。

本文研究运维任务生成中的检索与证据组织，不涉及由大语言模型直接估计电池寿命。主要贡献如下：

1. 提出一种规程、工单、状态和预测卡的分源异构检索框架，显式区分语义匹配与设备、时间、型号及版本等精确约束；
2. 以事件时间 $t_e(e)$ 、可用时间 $t_a(e)$ 与查询截止时刻 t_q 共同定义知识快照，并实施任务相关的历史窗口与新鲜度检查；
3. 将规程分块命中恢复为完整章节，并用任务动作集合与依赖偏序评价具身运维计划，避免把单一线性顺序当作唯一合法顺序；
4. 构建可复现的先导实验，分别报告检索层、模板管线和真实模型结果，并按事件组进行配对与不确定性分析。

1.1. 相关工作与研究差异

时序检索与动态知识：MRAG 将查询内容与时间约束拆分建模，再联合语义与时间相关性进行排序 [6]。OKH-RAG 则用有序超图表示实体、事件及其先后关系，使检索路径保留知识演化次序 [7]。前者在排序阶段显式引入时间，后者侧重关系结构中的顺序传播。

结构化与混合检索：DPR 通过双编码器将查询与段落映射到同一向量空间，以内积完成大规模候选检索 [8]。RRF 不重新训练检索器，而是按各列表中的名次合并结果 [9]。HybridRAG 进一步结合知识图谱与向量检索，使结构关系和文本语义共

*作者单位、通信作者及基金信息。

同进入上下文 [10]。三者分别代表稠密表示、后融合与结构化知识增强三条技术路线。

层级文档与机器人规划：RAPTOR 对文本递归聚类并生成摘要，形成可在不同粒度检索的树状索引 [11]。SayComply 把操作要求、环境条件和机器人能力组织为层级知识，用检索结果约束现场任务规划 [2]。SayCan 将语言模型给出的任务相关性与技能价值函数结合，用环境可行性对动作选择重新排序 [12]。这些工作分别从文档层级、规程合规和物理可行性处理长程任务规划。

工业与电池运维：RAGLRO 将检索增强生成用于电力开关柜机器人的操作规划 [3]。LiBrain 组合在线监测、诊断预测引擎与知识检索，用于电动自行车锂电池诊断 [4]；TimeSeries2Report 把多变量电池时序整理成结构化语义报告，供语言模型进行状态管理 [5]。工业运维研究由此逐步从静态文档问答扩展到状态感知和动作生成。

2. 问题定义与符号约定

给定运维请求文本 x_q 及其知识截止时刻 t_q ，解析得到目标设备 u_q 和任务类型 τ_q 。本文将结构化查询表示为 $Q_q = (x_q, u_q, t_q, \tau_q)$ 。其中， t_q 由查询元数据给定，不假设系统已具备从任意自然语言中抽取时间范围的能力。证据集合为 $K = K^{\text{doc}} \cup K^{\text{wo}} \cup K^{\text{state}} \cup K^{\text{pred}}$ ，分别对应规程、工单、状态和预测记录。

系统先检索与当前请求匹配的证据，再生成工单和依赖动作：

$$\begin{aligned} E_q &= \text{Retrieve}_{\tau_q}(x_q, u_q, t_q; K), \\ y_q^{(0)} &= f_{\text{DS}}(x_q, E_q). \end{aligned} \quad (1)$$

式 (1) 中， Retrieve_{τ_q} 是按任务类型选择数据源的检索过程； f_{DS} 是实验使用的基座生成模型，服务端别名为 `deepseek-v4-flash`。模型参数保持服务端既定状态，实验未进行训练或微调。生成动作序列记为 $A_q = (a_1, \dots, a_n)$ ；参考标注分别给出动作集合 A_q^* 和依赖关系集合 D_q^* 。若 $(a_i, a_j) \in D_q^*$ ，则动作 a_i 必须先于 a_j ，后继动作还需显式列出该依赖。

3. TMC-RAG 方法

TMC-RAG 以来源结构和证据适用性为检索组织依据，将多源检索、时间可见性、章节恢复和有界修复连接为统一流程。图 1 展示信息流及三个关键机制：基于截止时刻的知识快照、原始章节恢复，以及生成后检查与离线参考评价的分离。各方法的工程标识仅在附录中给出。

3.1. 异构证据表示与任务路由

每条证据保留来源标识、类型、设备关联、时间戳与版本元数据，同时保留各源的内部结构。规程记录章节、页码、适用型号、有效区间和文件指纹；工单记录故障码、状态和处理结果；状态记录温度、电压、电流、荷电状态及电芯压差；预测记录保存目标量、时域、输入窗口、模型版本与不确定性状态。统一外层表示用于追踪来源，不将所有证据强制转换为同一种文本。

检索前先确定目标设备和任务类型。任务分为历史查询、当前状态、规程前置条件、动作顺序、短时预测和证据不足处理六类。若请求中出现相互冲突的设备编号，或“它”“该设备”等代词无法唯一指向某台设备，系统要求补充信息，不自行猜测目标。

确定任务后，系统分别查询各数据源。历史查询读取目标设备在时间窗口 Δ_h 内的工单；其余任务先读取目标设备最新的可见状态；短时预测还要读取同设备且时间对齐的预测记录。规程只与规程比较相关性，不与状态或工单混在同一个排行榜中。每类任务预先规定各数据源最多返回多少条证据，例如最多 4 个规程章节、3 条工单、1 条状态和 1 条预测，避免某一类数据占满整个证据包。

3.2. 查询时刻可见性与动态证据选择

证据能否用于回答同时取决于它何时发生，以及何时进入系统。用 $\text{Visible}(e, q)$ 表示查询 q 能否使用证据 e ：

$$\text{Visible}(e, q) = \begin{cases} 1, & t_a(e) \leq t_q \text{ 且 } t_e(e) \leq t_q \text{ (若有)}, \\ 0, & \text{其他情况}. \end{cases} \quad (2)$$

这里， $t_a(e)$ 是证据进入系统的时间， $t_e(e)$ 是事件实际发生的时间， t_q 是回答所允许使用知识的截止时刻。证据必须在 t_q 之前入库；若记录了事件时间，事件本身也必须已经发生。例如，某告警在 10:00 发生、10:10 才入库，那么截止时刻为 10:05 的查询不能使用它。可用证据组成知识快照 $K(t_q) = \{e \in K : \text{Visible}(e, q) = 1\}$ 。全部对照方法使用同一快照。

同一工单的可见版本按可用时间保留最新记录。令 $\omega(e)$ 为工单身份标识，对给定工单 ω ，采用

$$e_{\omega}^* \in \arg \max_{e \in K^{\text{wo}}(t_q), \omega(e)=\omega} t_a(e). \quad (3)$$

随后对非文档证据施加设备条件 $u(e) = u_q$ 。历史工单和预测记录分别满足

$$\begin{aligned} 0 &\leq t_q - t_e(e) \leq \Delta_h, & e &\in K^{\text{wo}}, \\ 0 &\leq t_q - t_e(e) \leq \Delta_p, & e &\in K^{\text{pred}}. \end{aligned} \quad (4)$$

历史记录在筛选后按事件时间倒序选择。状态源则选择目标设备的最近可见记录；当记录不存在或其

Table 1. 主要符号及定义

符号	含义
Q_q, x_q, u_q, τ_q	查询、请求文本、目标设备与任务类型
t_q	回答可使用知识的截止时刻
$t_e(e), t_a(e)$	证据 e 的事件发生时刻与首次进入系统的时刻
$\text{Visible}(e, q)$	查询 q 能否使用证据 e ; 可用为 1, 否则为 0
$u(e), m_q$	证据对应的设备与目标设备 u_q 的型号
$v(e)$	证据版本标识
M_d, t_d^-, t_d^+	规程 d 的适用型号集合、生效时刻与失效时刻
$\text{Applicable}(d, q)$	规程 d 是否适用于查询 q ; 适用为 1, 否则为 0
$\Delta_h, \Delta_s, \Delta_p$	历史窗口、状态新鲜度阈值与预测新鲜度阈值
E_q, B	查询 q 的证据包与上下文字符预算
$h(c)$	文档分块 c 所属的原始章节
$y_q = (W_q, A_q)$	生成结果: 结构化工单与动作序列
A_q^*, D_q^*	参考动作集合与动作依赖关系集合
$V_{\text{run}}, V_{\text{task}}$	运行期综合校验与任务协议校验函数
Y_q^*, G_q	固定参考标注与其中的必要证据集合

年龄超过 Δ_s 时, 设置陈旧状态标志并交由后续检查处理, 而非宣称所有陈旧记录均已在检索时删除。预测记录保留预测时域和版本信息。

3.3. 规程适用性与层级恢复

规程必须同时满足两个条件: 支持目标设备的型号, 并且在查询时刻仍处于有效期。用 m_q 表示目标设备的型号, 用 M_d 表示规程 d 支持的型号集合, 则

$$\text{Applicable}(d, q) = \begin{cases} 1, & m_q \in M_d \text{ 且 } t_d^- \leq t_q < t_d^+, \\ 0, & \text{其他情况.} \end{cases} \quad (5)$$

其中, t_d^- 和 t_d^+ 分别是规程的生效与失效时刻。返回 1 表示规程可用于当前查询, 返回 0 则将其排除。无失效日期的规程视为长期有效, 即 $t_d^+ = +\infty$ 。型号、版本和有效期均来自规程元数据, 筛选通过后才进行内容相关性排名。

设按相关性排序并去除重复章节后的命中分块为 $c_1, \dots, c_K$, 其原章节候选为 $\{h(c_1), \dots, h(c_K)\}$ 。系统按排序顺序装入完整章节, 并满足

$$E_q^{\text{doc}} \subseteq \{h(c_1), \dots, h(c_K)\}, \quad \sum_{e \in E_q} \ell(e) \leq B, \quad (6)$$

其中 $\ell(e)$ 为证据 e 的字符占用。系统按排名依次装包, 不求解额外的组合优化; 剩余预算不足时跳过整个章节, 不截断章节内部步骤。

3.4. 候选生成与一次受控修复

DeepSeek 生成器 f_{DS} 接收请求和证据包, 输出工单 W_q 及动作序列 A_q 。工单包含目标设备、截止

时刻、当前状态、历史结果、预测量、责任信息、引用与未知项; 动作包含名称、目标设备、依赖和引用。运行期校验 V_{run} 检查输出结构、证据与时间一致性, 以及任务协议 V_{task} 。JSON Schema 符合性单独计分。

若初始结果未通过 V_{run} , 系统把原证据、原结果和错误列表 $r_q^{(0)}$ 再提交给同一模型, 最多生成一个修复结果 $\tilde{y}_q$ 。最终选择规则为

$$y_q^{\text{final}} = \begin{cases} \tilde{y}_q, & V_{\text{run}}(y_q^{(0)}, E_q) = 0 \wedge \\ & V_{\text{run}}(\tilde{y}_q, E_q) = 1, \\ y_q^{(0)}, & \text{其余情况.} \end{cases} \quad (7)$$

生成和修复只使用 x_q 与 E_q , 不读取参考标注 Y_q^* , 修复阶段也不追加检索。任务协议允许在证据不足时请求补充信息; 参考评分仍按原任务检查字段与动作, 因此协议通过率和任务完成率分别报告。

4. 实验设计

4.1. 数据与划分

本研究采用合成先导数据, 包含 24 台虚拟设备、60 个事件、240 条基础查询、4,080 条遥测和 416 条证据。每种任务包含 10 个按时间排序的事件, 依次分配 6 个、2 个和 2 个事件至开发集、验证集与测试集; 同一事件的 4 种改写不跨划分。

困难开发集从 12 个开发集事件构造 48 条可回答查询, 包括设备表述变化、任务改写、邻机指代和同设备时间对比; 另有 36 条不可回答解析样本, 只用于路由测试。派生检索库加入过期规程和查询后到达的冲突状态, 以验证版本和时间边界。




Figure 1. TMC-RAG 总体框架与关键机制。上部为查询条件化的四源检索与候选生成流程；下部依次展开事件时间与可用时间的双重约束、分块到原章节的恢复，以及参考标注只进入离线评价的边界。实线表示证据或候选流，虚线表示查询条件、受限修复或离线评分关系。图中的时间点和动作节点均为机制示意。

实验使用的真实文档是 Victron Energy 公开发布的《Lithium NG 51.2V battery manual, 100Ah》Rev 11 (03/2026) [13]，从中解析出 64 个规程章节。该手册只提供文档层级和规程文本；虚拟设备、工单、状态、预测与动作标签仍为合成数据，未将它们表述为 Victron 产品的真实运行记录。短时预测卡来自未标定的简化温度模型，不能作为 SOH 或 RUL 验证。

4.2. 对比方法

比较设置包含三类：统一检索基线、分源中间对照，以及完整方法及其消融。“排名”指把候选证据按相关性从高到低排列。词法排名使用 BM25，根据查询与证据中相同或相近的词、设备编号和故障码计算相关性；稠密排名先用独立的文本编码器把查询与证据转换为向量，再按向量相似度排序，因此即使措辞不同也可能匹配。例如，“电池包温度异常”和“电池过热”的字面重合较少，但其向量可能接近。这里的文本编码器只参与检索，不是生成答案的 DeepSeek 模型。

统一基线包括 BM25-RAG、Dense-RAG 和 Hybrid-RAG，分别采用词法排名、稠密排名，以及通过倒数排名融合 (RRF) 合并两份排序。Routed-

RAG 按任务分源并过滤结构化目标设备，但不限制规程型号/有效期，也不恢复完整章节。

完整方法 TMC-RAG 采用源级约束，并在规程文档内部使用 BM25 词法排名；TMC-RAG-H 将这一步替换为词法和稠密排名融合。三项单因素消融分别为：去除章节恢复 (w/o HR, hierarchical restoration)、去除附加时间过滤 (w/o TF, temporal filtering) 和去除预测证据 (w/o FE, forecast evidence)。w/o TF 仍保留式 (2) 的基础可见性快照，只移除历史窗口、预测新鲜度过滤及状态陈旧标志。以上名称与冻结实现一一对应，命名调整不改变任何配置。

4.3. 设置与执行协议

每类任务 10 事件中，开发集为 6 事件、验证集与测试集各 2 事件；本论文困难开发集从其中每类 2 事件构造，共 12 事件，而非使用全部 36 个基础开发集事件。任务类别与第 3.1 节一致。四类困难表达为实体表述变化、任务改写、邻机指代及同设备时间对比，每类覆盖 12 事件各一次。36 条不可回答路由样本不计入 48 条生成评价的分母。

统一检索保留排名前 $k = 8$ 项；分源方法最多取 4 个不同规程章节，历史任务最多取 3 条工单，

其他任务取 1 条最近状态，预测任务另取 1 张预测卡。两类配置均受 16,000 字符证据预算约束；因此预算口径相同，但实际证据条数和词元并不固定相等。分块长度 600 字符、重叠 80 字符；完整章节装包不足时跳过该章节。历史窗口 86,400 秒，状态/预测新鲜度阈值 60 秒，预测时域 60 秒。所有方法共享可见性快照与工单可见最新版本选择。w/o TF 移除历史窗口、预测新鲜度过滤及状态陈旧标志，不移除基础可见性条件。

稠密方法采用本地量化多语言 MiniLM ONNX 编码器，attention-masked mean 池化、向量归一化和 128 词元截断；模型修订标识见附录。RRF 常数为 60，按两路排名的倒数和融合 [9]。生成器使用 DeepSeek 服务端别名 `deepseek-v4-flash`，采样温度为 0，关闭额外思考模式，最大输出长度为 4,096 词元。修复只接收原证据、初始结果与错误列表。运行冻结涵盖源文件、配置、协议、查询顺序与运行顺序。

4.4. 评价指标与统计单位

检索评价包括必要证据召回、必要来源覆盖、全部必要证据命中率及完整章节覆盖。令 G_q 为查询 q 的必要证据集合， I_q 为检索证据及其源章节的标识集合，主表采用查询宏平均

$$R_{\text{macro}} = \frac{1}{N} \sum_{q=1}^N \frac{|G_q \cap I_q|}{|G_q|}. \quad (8)$$

分源召回按各源必要证据的命中和出现次数求比，故其分母与式 (8) 不同。完整章节覆盖先计算每个查询的必要原章节覆盖比例，再取平均；无必要规程时评分器约定为 1。该指标不判断句段语义蕴含。边界问题按检索包中的出现次数累计，同一证据在不同查询中重复出现时分别计数。

生成评价采用逐查询的字段联合正确指标 F_q 和计划有效指标 P_q ，两者的查询均值构成相应通过率；另报告任务协议通过率和引用存在率。 $F_q = 1$ 要求结构形状检查通过，且设备、截止时刻、状态、历史结果集合、温度、预测值与预测时域 7 项均符合固定参考标注；数值绝对容差为 0.001。 $P_q = 1$ 要求动作集合、目标、唯一性与依赖顺序满足参考评分规则。任务协议进一步检查显式依赖，而引用存在只表示标识可解析，不能替代语义支持评价。

为区分协议通过与参考任务完成，定义组合诊断量

$$C_q = F_q P_q. \quad (9)$$

由于 F_q 和 P_q 都只取 0 或 1，只有字段与计划同时正确时 $C_q = 1$ 。分别统计在最终 $V_{\text{task}} = 1$ 的查询中 $P_q = 0$ 和 $C_q = 0$ 的数量，以协议通过的查询数为分母。该指标用于识别“协议已通过、原任务仍未完成”的情况。修复以查询为单位配对统计改善、退化及其差额；净收益比例以全部查询数为分母。计

算成本采用服务端报告的总词元数，计时采用保存的原始管线与修复耗时。

同一事件的四种改写共享证据状态，统计单位为事件而非单条改写。对方法 m 与参照方法 r ，先在事件 j 内求指标差，再等权汇总：

$$\delta_j = \frac{1}{n_j} \sum_{q \in Q_j} (s_q^{(m)} - s_q^{(r)}), \quad \hat{\Delta} = \frac{1}{J} \sum_{j=1}^J \delta_j. \quad (10)$$

其中 s_q 为待比较的查询级评分， Q_j 为事件 j 的查询集合；当前 $J = 12$ 、 $n_j = 4$ 。配对 bootstrap 在事件层重采样 2,000 次并报告百分位 95% 区间。

5. 实验结果

5.1. 检索基线 with 消融

Dense-RAG 和 Hybrid-RAG 在本数据上的必要证据召回分别为 6.77% 和 23.26%，均低于 BM25-RAG 的 46.70%。精确设备标识、数值字段、异构源竞争、128 词元截断和领域差异都可能影响这一结果，但现有实验没有逐项区分这些因素。加入分源路由后，必要源覆盖由 BM25-RAG 的 66.67% 提高到 100%，说明源选择是本数据上最主要的改变量。

w/o HR 与 TMC-RAG 的必要证据 ID 召回相同，完整章节覆盖则由 75% 降至 0，二者分别反映证据标识命中和章节上下文完整性。w/o TF 的证据召回没有变化，字段联合正确率下降 33.33 个百分点；时间窗口影响的是入选记录及其当前性。w/o FE 缺少预测证据，字段和计划均下降 16.67 个百分点。

5.2. 分源检索结果

TMC-RAG 对工单、状态和预测证据的分源命中均为 100%，规程文档为 56/72 (77.8%)。缺失项主要来自需要多个规程章节的查询。TMC-RAG-H 的规程命中为 41/72，比词法配置少 15 条，因此主方法采用词法文档排名。

5.3. 设备、时间和规程边界

公共知识快照排除了查询时刻之后才可见的记录，六种方法的未来证据计数均为 0。三种统一检索配置没有目标设备过滤，错设备证据累计为 141 至 304 次。Routed-RAG 消除了结构化数据中的错设备证据，但仍返回 22 次错型号规程和 40 次过期规程；加入型号与版本过滤后，这两项计数降为 0。

Table 2. 九方法开发集检索矩阵及模板诊断 (各 48 查询)

方法	必要证据召回	必要源覆盖	全部证据命中	完整章节覆盖	字段全对 [†]	计划有效 [†]
BM25-RAG	46.70%	66.67%	20.83%	0.00%	70.83%	87.50%
Dense-RAG	6.77%	27.08%	0.00%	0.00%	22.92%	39.58%
Hybrid-RAG	23.26%	34.72%	0.00%	0.00%	43.75%	62.50%
Routed-RAG	82.29%	100.00%	54.17%	0.00%	100.00%	100.00%
w/o HR	86.11%	100.00%	66.67%	0.00%	100.00%	100.00%
w/o TF	86.11%	100.00%	66.67%	75.00%	66.67%	83.33%
w/o FE	81.94%	94.44%	50.00%	75.00%	83.33%	83.33%
TMC-RAG	86.11%	100.00%	66.67%	75.00%	100.00%	100.00%
TMC-RAG-H	75.35%	100.00%	41.67%	57.29%	100.00%	100.00%

[†] 字段和计划来自确定性模板，只用于验证检索包与程序逻辑，不是 LLM 性能。

Table 3. 必要证据分源命中 (跨查询出现次数)

方法	规程文档	历史工单	状态	预测
BM25-RAG	14/72 (19.4%)	7/8 (87.5%)	28/40 (70.0%)	8/8 (100.0%)
Dense-RAG	0/72 (0.0%)	4/8 (50.0%)	3/40 (7.5%)	1/8 (12.5%)
Hybrid-RAG	0/72 (0.0%)	8/8 (100.0%)	17/40 (42.5%)	4/8 (50.0%)
Routed-RAG	50/72 (69.4%)	8/8 (100.0%)	40/40 (100.0%)	8/8 (100.0%)
TMC-RAG	56/72 (77.8%)	8/8 (100.0%)	40/40 (100.0%)	8/8 (100.0%)
TMC-RAG-H	41/72 (56.9%)	8/8 (100.0%)	40/40 (100.0%)	8/8 (100.0%)

Table 4. 检索完整性问题累计次数

方法	错设备	未来证据	错型号规程	无效规程版本
BM25-RAG	141	0	6	14
Dense-RAG	304	0	0	0
Hybrid-RAG	236	0	0	0
Routed-RAG	0	0	22	40
TMC-RAG	0	0	0	0
TMC-RAG-H	0	0	0	0

5.4. 真实模型结果

按照第 4.3 节所列 `deepseek-v4-flash` 配置，48 条开发集困难查询分别运行 BM25-RAG、Routed-RAG、TMC-RAG 和 TMC-RAG-H。四个完整运行均无接口或 JSON 解析失败。Routed-RAG 与 TMC-RAG 使用相同的查询、提示、DeepSeek 生成器、任务协议和修复设置，仅检索过程不同。

四种方法共记录 224 次模型调用，服务端报告总词元为 862,076。

Routed-RAG、TMC-RAG 和 TMC-RAG-H 的 24 次修复均发生在规程前置条件任务，错误类型是多余的测温动作，或缺失上传动作及其依赖。BM25-RAG 的 8 次修复中，5 次改善参考计划，3 条短时预测却由“就绪”变为“请求补充信息”。后 3 条通过任务协议，但不再完成固定参考任务。

Routed-RAG 与 TMC-RAG 的最终字段和计划指标均为 48/48，检索层却存在明显差异：前者的必要证据召回为 82.29%、完整章节覆盖为 0，并累计返回 40 次过期规程和 22 次错型号规程；后者的两项覆盖指标为 86.11% 和 75%，四类完整性问题均为 0。对 Routed-RAG 最终结果的 217 次引用进行离线审计后，23 次引用在对象、时间、证据类型或结构化字段上不能支持对应声明或动作，另有 82 次规程引用超出自动规则的判定能力。由此，修复后的任务得分和检索完整性需要作为不同层次的结果报告。

5.5. 事件级配对分析

以 12 个事件为统计单位，TMC-RAG 相对 BM25-RAG 的最终字段联合准确率平均提高 0.50，事件级 bootstrap 95% 区间为 [0.3125, 0.6875]；最终计划有效率平均提高 0.1458，区间为 [0.0625, 0.25]。TMC-RAG 与 TMC-RAG-H 在这 12 个事件上的字段和计划得分相同，差值及区间均为 [0, 0]。这一零宽区间来自当前样本全部打平，不包含未见事件的泛化不确定性。

每个事件的 4 种改写先在事件内合并，未作为 48 个独立事件计算区间。




Figure 2. 开发集检索效果与完整性边界。左侧比较必要证据召回和完整章节覆盖，右侧统计检索包中的错设备、错型号规程及无效规程版本。

Table 5. 四方法开发集真实模型结果 (各 48 查询)

方法	字段全对 (原始 → 最终)	参考计划 (原始 → 最终)	任务协议 (原始 → 最终)	修复尝试/接受	总词元
BM25-RAG	24/48→24/48	39/48→41/48	40/48→48/48	8/8	233,834
Routed-RAG	48/48→48/48	40/48→48/48	40/48→48/48	8/8	182,793
TMC-RAG	48/48→48/48	40/48→48/48	40/48→48/48	8/8	208,766
TMC-RAG-H	48/48→48/48	40/48→48/48	40/48→48/48	8/8	236,683

5.6. 冻结后的验证集与测试集

主方法、检索实现、提示、任务协议、指标、修复策略、模型设置、查询标识顺序和运行顺序均在读取验证集与测试集结果前写入预登记冻结清单。随后仅运行 TMC-RAG，依次在验证集和测试集各运行一次；两个运行的冻结协议与预登记文件哈希全部匹配。

两个划分的原始计划错误均集中在 8 条规程前置条件查询：缺少上传证据动作及依赖，或多出任务范围外的测温动作；至多一次修复后全部通过。验证集结果没有用于新增规则、调参或筛选测试集配置。验证集和测试集具有相同的合成任务结构，因此相同得分主要说明冻结流程得到复现。

5.7. 真实模型模块消融

在主方法及验证集与测试集封存后，本文按预登记顺序仅在开发集补充三项真实模型单因素消融。模型、提示、任务协议和修复设置不变，结果不用于回改系统。

移除时间窗口后，8 条历史查询全部混入窗口外工单，最终字段联合正确下降 16.67 个百分点；式 (2) 的基础可见性快照仍保留，所以未来证据计数为 0。移除预测卡后，8 条短时预测查询缺少预测字段并输出“请求补充信息”，最终字段和参考计划均下降 16.67 个百分点，而任务协议仍为 48/48。

移除章节恢复使完整章节覆盖从 75% 降为 0，当前字段与程序化计划指标没有随之下降；现有任务尚未把章节上下文差异传导到生成评分。以事件为单位的配对 bootstrap 中，w/o TF 与 w/o FE 相对主方法的最终字段差均为 -0.1667，95% 区间为 [-0.4167, 0]；w/o FE 的最终计划差也为 -0.1667，区间相同。

5.8. 任务分层、修复收益与评价差距

补充分析依据七种方法已保存的开发集结果开展，不新增模型调用，也不重新评价验证集与测试集。表 8 按任务定位主方法的残余证据缺口，每任务 8 查询来自 2 事件。

规程缺口集中在动作顺序和证据不足处理两类任务，必要证据召回分别为 66.67% 和 50.00%。主方法未命中全部必要证据的 16 条查询来自 4 个事件，这一子组的最终字段和计划仍为 16/16。Routed-RAG 有 44/48 条检索包存在完整性问题，对应子组的最终字段和计划仍为 44/44。

四类困难表达下，主方法各 12 条查询的召回均为 86.11%、完整章节覆盖均为 75%，字段均为 12/12，计划均由 10/12 修复至 12/12。Routed-RAG 在实体表述、任务改写、邻机指代和时间对比上的召回依次为 86.11%、80.56%、80.56% 和 81.94%。这些改写共享固定的事件与任务模板，分层一致性只覆盖当前模板集合；完整七方法结果见补充报告。




Figure 3. 真实模型开发集生成结果与词元。左侧为修复前后的计划有效率，右侧为服务端报告的总词元。




Figure 4. TMC-RAG 相对 BM25-RAG 的事件级配对区间。点估计、事件级 95% bootstrap 区间及事件胜/平/负同时给出。原始计划差的区间跨越 0，修复后的最终计划差区间不跨 0。

BM25 的 3 条计划退化均与“就绪”→“请求补充信息”修复共现，净增为 2/48；主方法净增为 8/48 且无计划退化。w/o FE 的 8 条预测查询在原始候选已为“请求补充信息”，故该保守状态并非由后续修复引起。其 15 次修复中 8 条改善参考计划，另 7 条未改变参考计划通过状态。任务协议允许保守响应，而参考标注仍评价原任务，解释了 8/48 的协议—计划差距。w/o TF 的计划满分而字段存在 8 条错误，说明仅看计划差距仍不足以反映全部未完成情况。

主方法修复词元占总量 16.17%，原始管线和修复计时之和分别为 131.58 秒、21.21 秒；w/o FE 修复词元占 27.17%，修复计时 38.76 秒。上述成本来自一次顺序运行，不能据服务时延波动推断部署吞吐。现有最小审计仅提供方法级成本，故不报告无法由该审计粒度确定的任务级成本。

以“对照 - 主方法”为差值方向，Routed-RAG 的事件级召回差为 -0.0382，95% 区间为

$[-0.0799, -0.0052]$ ，12 个事件中 0 胜、8 平、4 负；字段且计划完成差为 0，区间为 $[0, 0]$ 。w/o TF 与 w/o FE 的字段且计划完成差均为 -0.1667，区间为 $[-0.4167, 0]$ 。这些区间未作多重比较校正。

6. 讨论

6.1. 分源检索的适用性

统一检索将规程文本、工单记录、状态值和预测卡压入同一相似度空间，前 k 项需要同时承担源选择、设备解析和内容相关性排序。分源路由把源选择显式化，使关系型字段由精确过滤处理、时序数据由时间窗口处理、文档内容才由文本相关性排序。这种分工更符合异构数据自身的查询语义。

Table 6. 冻结后的主方法独立划分结果 (各 48 查询)

划分	生成失败	字段全对 (原 → 终)	参考计划 (原 → 终)	任务协议 (原 → 终)	修复尝试/接受	证据召回	整节覆盖	总词元
验证集	0	48/48→48/48	40/48→48/48	40/48→48/48	8/8	86.11%	75.00%	208,153
测试集	0	48/48→48/48	40/48→48/48	40/48→48/48	8/8	86.11%	75.00%	207,976

Table 7. 开发集真实模型单因素消融 (各 48 查询)

方法	证据召回	整节覆盖	字段全对 (原 → 终)	计划有效 (原 → 终)	任务协议 (原 → 终)	修复尝试/接受	总词元
TMC-RAG	86.11%	75.00%	48/48→48/48	40/48→48/48	40/48→48/48	8/8	208,766
w/o HR	86.11%	0.00%	48/48→48/48	40/48→48/48	40/48→48/48	8/8	179,013
w/o TF	86.11%	75.00%	40/48→40/48	41/48→48/48	41/48→48/48	7/7	207,333
w/o FE	81.94%	75.00%	40/48→40/48	32/48→40/48	33/48→48/48	15/15	235,739

Table 8. 主方法按任务分层的开发集结果

任务	证据召回	整节覆盖	字段 (原 → 终)	计划 (原 → 终)
历史查询	100.00%	100.00%	8→8	8→8
当前状态	100.00%	100.00%	8→8	8→8
规程前置条件	100.00%	100.00%	8→8	0→8
动作顺序	66.67%	50.00%	8→8	8→8
短时预测	100.00%	100.00%	8→8	8→8
证据不足处理	50.00%	0.00%	8→8	8→8

6.2. 语义融合的负结果及可能原因

当前语义编码器使用 128 词元截断，长规程分块可能丢失后部条件；困难查询又包含设备 ID、时间和任务表达，通用句向量不一定保留这些精确符号。这些是机制假设，尚未单独控制验证。RRF 融合会改变固定文档源配额内的候选排序，使原本可由 BM25 命中的章节退出前 k 项。因此本文只报告当前负结果，不将其外推为稠密检索在其他数据或训练条件下无效。

6.3. 研究定位与工程含义

来源结构、时间可见性和规程适用性在管线中均对应可单独审计的中间结果。实验中，Routed-RAG 与 TMC-RAG 取得相同的最终任务分数，但检索完整性不同；w/o FE 则通过任务协议，却没有完成部分参考任务。这两组现象说明，单一终端分数难以定位错误发生在检索、生成还是协议判定阶段。实际部署前仍需在独立数据上补充语义支持校验和执行层验证。

7. 局限性与有效性威胁

1. **数据真实性**：设备、工单、状态、预测和查询主要为固定随机种子合成数据，只有公开手册是真实资料。
2. **样本独立性**：48 条查询来自 12 个事件，每个

事件包含 4 种改写，不能当作 48 个独立事件。

3. **引用评价**：引用 ID 存在不等于语义支持；当前自动支持审计对规程和物理动作仍有无法判定项。
4. **预测边界**：当前仅有未校准的 60 秒温度预测卡，不包含经过验证的 SOH、退化趋势或 RUL。
5. **模态与空间**：系统没有图像、热成像或视频流，也没有真实站级拓扑、设备坐标和机器人闭环执行，因此本文使用“多源异构”，不声称完成真正的视觉多模态时空对齐。
6. **开发集饱和**：Routed-RAG 与完整约束方法在修复后生成指标上相同，而检索完整性存在差异；当前任务和程序化指标不足以把错误规程稳定传导为可观测生成失分。

8. 结论

本文构建了面向储能电站运维任务规划的 TMC-RAG 原型。该方法按来源检索规程、工单、状态和预测记录，以设备、时间、型号与版本条件筛选证据，并恢复命中分块所在的完整章节。开发集上，分源路由将必要源覆盖提高到 100%；TMC-RAG 的必要证据召回为 86.11%，完整章节覆盖为 75%，且检索包中没有出现错设备、错型号和无效规程。冻结后的验证集与测试集各执行一次，字段与修复后计划均为 48/48。消融实验进一步定位了时间窗口、预测卡和章节恢复分别影响字段当前性、原任务完成和上下文完整性。当前生成评分已出现饱和，而规程召回与引用语义支持仍有缺口。以上结果限于合成先导数据；真实运维表达、站级拓扑、视觉证据及机器人执行仍需独立验证。

References

- [1] P. Lewis, E. Perez, A. Piktus, *et al.*, “Retrieval-Augmented Generation for Knowledge-Intensive




Figure 5. 开发集真实模型消融中的检索完整性与生成饱和。两面板颜色各对应其图例，纵轴方法一致；章节恢复的可观测收益目前位于检索层。

Table 9. 修复净收益及最终协议与任务完成差距 (各 48 查询)

方法	计划改善/退化/净增	协议通过但计划未完成	协议通过但字段或计划未完成	修复词元/总词元
BM25-RAG	5/3/+2	7/48	24/48	37,927/233,834
Routed-RAG	8/0/+8	0/48	0/48	30,631/182,793
TMC-RAG	8/0/+8	0/48	0/48	33,753/208,766
TMC-RAG-H	8/0/+8	0/48	0/48	36,945/236,683
w/o HR	8/0/+8	0/48	0/48	30,034/179,013
w/o TF	7/0/+7	0/48	8/48	29,571/207,333
w/o FE	8/0/+8	8/48	8/48	64,051/235,739

- NLP Tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 9459–9474.
- [2] M. F. Ginting, *et al.*, “SayComply: Grounding Field Robotic Tasks in Operational Compliance through Retrieval-Based Language Models,” in *Proc. IEEE Int. Conf. Robotics and Automation (ICRA)*, 2025, pp. 13730–13736.
 - [3] W. Wang, *et al.*, “RAGLRO: Retrieval-Augmented Generation With Large Language Models for Robotic Operations,” *CAAI Transactions on Intelligence Technology*, vol. 11, no. 2, pp. 385–395, 2026, doi: 10.1049/cit2.70105.
 - [4] Z. Li, *et al.*, “LiBrain: LLM-Powered Lion Battery Diagnostics with Time-Series-Aware Retrieval-Augmented Framework for E-bikes,” in *Proc. AAAI Conf. Artificial Intelligence*, vol. 40, no. 47, 2026, pp. 40045–40053, doi: 10.1609/aaai.v40i47.41439.
 - [5] J. Yang, M. Guay, Z. Cao, and C. Zhao, “Time-Series2Report Prompting Enables Adaptive Large Language Model Management of Lithium-Ion Batteries,” arXiv:2512.16453v2, 2026.
 - [6] S. Zhang, Y. Xue, Y. Zhang, X. Wu, A. T. Luu, and C. Zhao, “MRAG: A Modular Retrieval Framework for Time-Sensitive Question Answering,” in *Findings of the Association for Computational Linguistics: EMNLP 2025*, 2025, pp. 3080–3118.
 - [7] K. Wu, *et al.*, “Knowledge Is Not Static: Order-Aware Hypergraph RAG for Language Models,” arXiv:2604.12185, 2026.
 - [8] V. Karpukhin, B. Oguz, S. Min, *et al.*, “Dense Passage Retrieval for Open-Domain Question Answering,” in *Proc. 2020 Conf. Empirical Methods in Natural Language Processing (EMNLP)*, 2020, pp. 6769–6781.
 - [9] G. V. Cormack, C. L. A. Clarke, and S. Buettcher, “Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods,” in *Proc. 32nd Int. ACM SIGIR Conf. Research and Development in Information Retrieval*, 2009, pp. 758–759.
 - [10] B. Sarmah, B. Hall, R. Rao, S. Patel, S. Pasquali, and D. Mehta, “HybridRAG: Integrating Knowledge Graphs and Vector Retrieval Augmented Generation for Efficient Information Extraction,” arXiv:2408.04948, 2024.
 - [11] P. Sarthi, S. Abdullah, A. Tuli, S. Khanna, A. Goldie, and C. D. Manning, “RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval,” arXiv:2401.18059, 2024.
 - [12] M. Ahn, A. Brohan, N. Brown, *et al.*, “Do As

I Can, Not As I Say: Grounding Language in Robotic Affordances,” arXiv:2204.01691v2, 2022.

- [13] Victron Energy B.V., *Lithium NG 51,2V Battery Manual: 100Ah*, Rev. 11, Mar. 2026. [Online]. Available: <https://www.victronenergy.com/>

upload/documents/Lithium_NG_battery_51,2_V/173204-Lithium_NG_battery_manual-pdf-en.pdf. Accessed: Sep. 8, 2026.